

Mémoire professionnel

Modélisation, Développement et Déploiement d'un outil de prédiction de la volumétrie des appels et des alarmes dans le monitoring

DIAKHATE MOUHAMADOU FADEL
Encadrement: Philippe NICLOU

24 août 2021



Sommaire

1	Introduction	7
2	Présentation de Stanley Security	9
2.1	Histoire et Fiche d'identité	9
2.1.1	Histoire	9
2.1.2	Fiche d'identité	9
2.2	La direction du groupe TSV	11
2.2.1	Organigramme du Monitoring	11
2.2.2	Organisation	12
2.3	La vision du groupe Stanley Security	12
2.3.1	Les activités du groupe Stanley Security :	13
2.3.2	Engagement du groupe pour un avenir durable	14
2.3.3	Quelques stratégies :	15
3	Le projet : Outils de prediction sur la volumétrie des appels et des alarmes	16
3.1	Revue de la littérature	16
3.2	Contexte et objectifs	17
3.3	Etude & Conception	18
3.3.1	Préparation des données	18
3.3.2	Explorations des données de la volumétrie des appels et des alarmes	19
3.3.3	Choix du modèle et des paramètres	21
3.4	Bilan	26
3.4.1	Volumétrie des Alarmes et des alarmes	26
3.4.2	Détermination des patterns des faux-positifs	28
4	Automatisation	32
4.1	Contexte et objectifs	32
4.2	Conception	32
5	Conclusion	34

Remerciements

Premièrement, je souhaite remercier mon tuteur Monsieur Philippe NICLOU, responsable des projets de télésurveillance dans le monitoring ainsi que mon collègue Louis Dobler, responsable technique du centre de télésurveillance qui m'ont accompagnée tout au long de cette alternance, en m'épaulant et en me guidant quotidiennement durant ma mission.

Je les remercie également pour les nombreux conseils qu'ils ont su m'apporter, le temps qu'ils ont consacré à me donner des pistes de réflexion ainsi que toute la confiance qu'ils m'ont accordée.

Je désire aussi remercier l'ensemble de mon service qui a su m'apporter soutien et bonne humeur au quotidien. J'ai pu élaborer ce mémoire professionnel dans de bonnes conditions.

Je tiens à remercier le corps professoral du Master Data Science de l'IA-School avec qui j'ai pu échanger sur le sujet de mon mémoire me permettant d'avoir une base de travail sur laquelle j'ai pu m'appuyer.

Je souhaite également remercier toutes les personnes qui ont participé directement ou indirectement à la construction de ce mémoire, en m'accordant de leur temps et en me donnant leur aide ainsi que de précieux conseils.

Glossaire

Résumé

Forecasting is an essential activity in a competitive and innovative environment. In a remote monitoring operator center, where service standards are regulated and salary costs are dominant, forecasting and salary costs are dominant, forecasting the volume of calls and alarms is the basis of its management of its management and profitability. We are developing a predictive tool for call and alarm volume based on data provided by monitoring centers.

The goal of this tool is to anticipate the organization of the personnel by optimizing the number of personnel to be employed and the priorities assigned to alarms.

We use SARIMA and Holt Winter time series models with the necessary adaptations to reach our objectives.

Our results indicate that SARIMA adjusts the activity of remote monitoring operator centers more favorably than Holt Winter due to seasonality.

Abstract

Forecasting is an essential activity in a competitive and innovative environment. In a telesurveillance operator center, where service standards are regulated and wage costs are dominant, forecasting the volume of calls and alarms is the basis of its management and profitability. Indeed we are developing a prediction tool on the volume of calls and alarms based on data provided by remote monitoring centers.

The purpose of this tool is to be able to anticipate the organization of staff in terms of call volumes, fluctuating and alarm processing in order of priority.

We use SARIMA and Holt Winter time series models with the necessary adaptations to the achievement of our objectives.

Our results indicate that SARIMA favorably adjusts the activity of telephone operator centers. monitoring rather than Holt Winter because of seasonality.

1 Introduction

Comme tout organisme vivant, une entreprise évolue constamment et se dirige vers ses objectifs pour assurer sa survie et son développement. Aujourd’hui, la capacité à fixer des objectifs et à les atteindre est fortement influencée par les innovations technologiques et l’automatisation.

Parmi les méthodes innovantes, l’Intelligence Artificielle (IA) occupe une place prépondrante. Elle recouvre l’ensemble des techniques permettant aux machines d’imiter une forme d’intelligence réelle, dont le machine learning. Autrement appelé apprentissage automatique, il est un champ d’étude de l’IA qui se fonde sur des approches mathématiques et statistiques pour donner aux ordinateurs la capacité d’apprendre à partir de données, c’est-à-dire d’améliorer leurs performances à résoudre des tâches sans être explicitement programmés pour chacune. Plus largement, il concerne la conception, l’analyse, l’optimisation, le développement et l’implémentation de telles méthodes. Dans les entreprises, on utilise de plus en plus le machine learning pour prédire des phénomènes donnés. Elle améliore les fonctions internes de l’entreprise et ses relations avec le monde extérieur de différentes manières. Le monde des affaires actuel étant dominé par l’IA, il est impensable de ne pas suivre cette tendance de développement qui ne peut que profiter à l’organisation et à la croissance de l’entreprise. Cette technologie a permis d’améliorer l’organisation du travail grâce à des prévisions pour les journées et pour les tâches à effectuer. Stanley Security nous a accueilli durant cette année d’alternance de Master 2 en Management Big data & IA.

En tant qu’Apprenti Ingénieur Data Scientist/Automation en alternance sur le site d’Ivry sur seine, nous sommes impliqués dans différentes missions, notamment :

- Modélisation d’un outil (par des méthodes de machine learning adaptées aux séries temporelles) de prédiction de la volumétrie des alarmes dans le monitoring.
- Modélisation d’un outil de prédiction de la volumétrie des appels entrants dans le monitoring.
- Déploiement d’outils de prédiction de la volumétrie des appels entrants et des alarmes
- Mise en place d’une solution d’analyse audio et vidéo en utilisant des méthodes de Deep Learning.
- Automatisation des tâches récurrentes et du reporting.
- Participation à la gestion de projet satisfaction clients

Leader en France, STANLEY Security est une société par actions simplifiée, active depuis 8 ans. Située à IVRY-SUR-SEINE (94200), elle est spécialisée dans le secteur des activités liées aux systèmes de sécurité. Elle propose des solutions de sécurité en télésurveillance pour les professionnels. Son effectif est supérieur à 1000 salariés. Sur l’année 2019 elle réalise un chiffre d’affaires de 165 930 700,00 €.

Depuis l’année passée le groupe Stanley Security s’est doté d’un premier outil de prediction de la volumétrie des alarmes en fonction de la granularité horaire. Ce dernier avait des limites :

- L’outil est créé sous Python avec le module TKinter qui produit les résultats des prédictions mais de manière locale (non déployé sur un serveur).
 - Il ne prenait pas en charge les appels entrants.
 - La solution aussi était une boîte noire (elle ne pouvait pas être re-modélisée par l’entreprise.)
- Le besoin d’améliorer l’outil de prédiction existant à mener à cette alternance.

C’est dans ce sillage que nous avons fait le choix de modéliser la volumétrie des appels et des alarmes en utilisant le modèle SARIMA, de développer un outil de prédiction via R Shiny user-friendly et de déployer l’outil via un server.

L’outil à trois fonctionnalités il donne une vue d’ensemble des données puis calcul les prédictions et enfin permet de faire les mises à jours de nouvelles données pour actualiser les prédictions.

Cet outil permettra aux centres concernés de répondre aux standards de l’industrie et de la concurrence.

C'est dans cette perspective que la suite de ce mémoire professionnel va être organisé.

Dans la partie 1 nous allons présenter Stanley Security en mettant l'accent sur le centre de télé-surveilance (TSV). Ensuite dans la partie 2 nous présenterons nos travaux. Ce chapitre se focalisera sur les outils de prédition puis l'automatisation. Enfin nous conclurons en ouvrant des perspectives et des point d'amélioration et de continuité.

Mots clés

- intelligence artificielle
- Previsions

Key words

- artificial intelligence
- Forecasts

2 Présentation de Stanley Security

2.1 Histoire et Fiche d'identité

2.1.1 Histoire

L'histoire de STANLEY BLACK et DECKER commence avec Frederick Stanley, Duncan Black, et Alonzo Decker. Depuis plus de 175 ans, nous préservons leur héritage avec fierté et avons fait de leur nom des succès commerciaux. En 1843, Frederick Stanley ouvre un magasin spécialisé dans la fabrication de boulons et matériaux en fer forgé dans le Connecticut (USA). La qualité des produits, l'innovation et l'intérêt porté à la recherche et au développement font le succès de la société Stanley Works. En 1910, Duncan Black et Alonzo Decker créent leur magasin dans le Maryland (USA). Ils se démarqueront six ans plus tard en déposant le brevet du premier outil électrique portatif. Les deux entreprises Stanley Works Black et Decker développeront leur portefeuille de marques et de produits pendant des décennies tout forgeant leur expertise industrielle. En 2010, Stanley Black et Decker se rapprochent pour former Stanley Black et Decker afin d'offrir des solutions adaptées aux besoins des entreprises industrielles, des professionnels et des consommateurs. Aujourd'hui nous continuons de préserver la réputation de notre groupe en mettant l'innovation au cœur de notre culture. Nous créons passion et engagement autour de nos marques pour satisfaire les exigences de nos clients.

2.1.2 Fiche d'identité

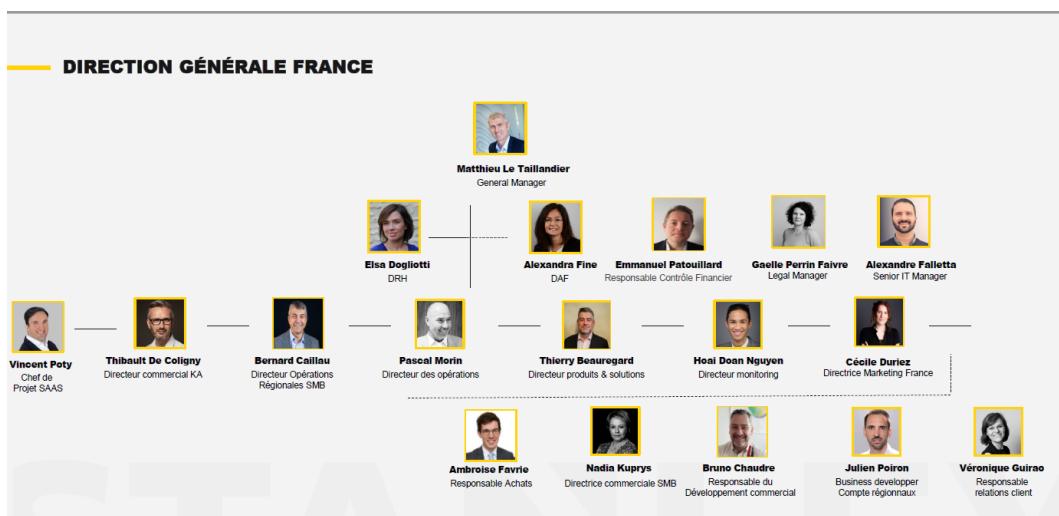


FIGURE 1 – Organigramme général de Stanley Security

Chiffres clés :

Le groupe Stanley Security est une équipe de professionnels engagés pour protéger vos collaborateurs, vos locaux et votre avenir. En effet cela se justifie par une compréhension profonde des besoins, afin de vous accompagner et de vous aider à promouvoir et à pérenniser vos activités.

Deuxième au niveau mondial de la sécurité professionnelle, le groupe Stanley Security possède 500.000 bâtiments avec un budget de 700 M euros dont 1,7 Milliard d'euros dans le monde entier.

1843 STANLEY® est fondée
#1 Outilage et Stockage
#2 Sécurité Electronique
#2 Systèmes de Fixations Techniques
+ de 52 000 employés dans 50 Pays
500 000 produits
+ de 13 000 brevets mondiaux actifs



FIGURE 2 – Le groupe Stanley en quelques chiffres



FIGURE 3 – Fiche d'identité du groupe Stanley Security

Le nombre d'arrestations de criminels est de 175000 depuis 1997 et le nombre de collaborateurs est de 5000. De plus elle a 3.000 ingénieurs qui sont dans le secteur de recherche et du développement avec aussi 160.000 clients qui sont protégés. Tous ces facteurs font qu'aujourd'hui elle est 6 e aux classements des entreprises dépositaires de brevet dans tout le monde entier.

En France le groupe Stanley sécurité détient 90.000 sites de sécurité dont 35 agences, 3 centres de télésurveillance, 200 opérateurs de télésurveillance, 600 techniciens et 30 experts de bureau d'étude.

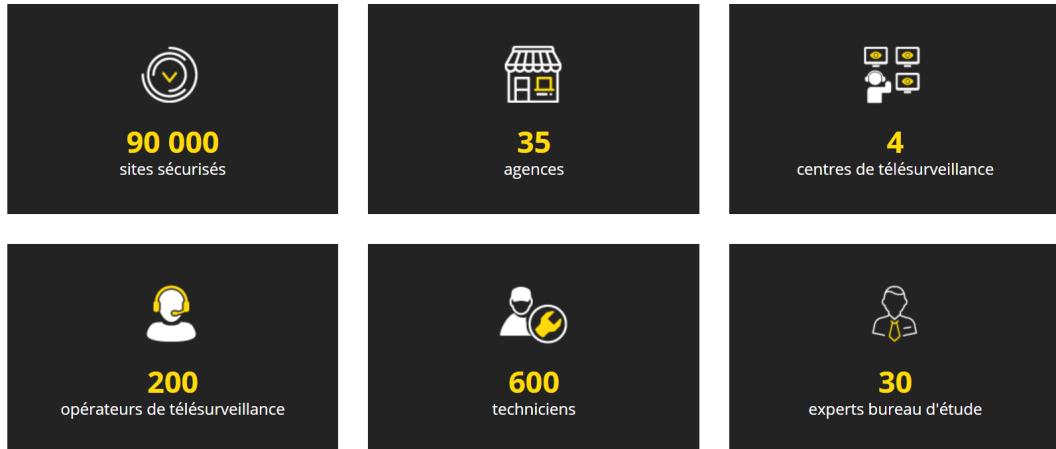


FIGURE 4 – Le groupe Stanley Security en France

2.2 La direction du groupe TSV

2.2.1 Organigramme du Monitoring

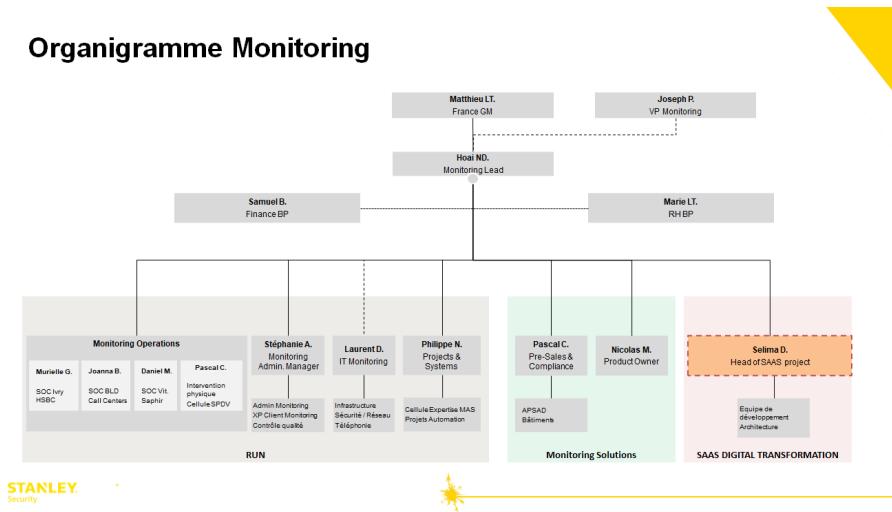


FIGURE 5 – Organigramme du Monitoring

2.2.2 Organisation

Leader de la sécurité et de la sûreté des entreprises Stanley conçoit, installe et maintient des solutions innovantes, connectées et intégrées pour favoriser un business plus simple et plus efficace en toute sérénité.

La présence de plusieurs experts et des technologies de télésurveillance professionnelles chez Stanley Security assure la sécurité des clients et particuliers. Ces nouvelles solutions de télésurveillance sont très avancées et intelligentes.

Parmi les trois centres de télésurveillance qui sont respectivement d'Ivry sur seine, Bar le duc et Vitrole, deux d'entre viennent d'être certifiés APSAD P5, le plus haut niveau de certification européens et le 3 e centre certifié P3 sera certifié P5 au cours de l'année 2021. Ces facteurs montrent un service d'assurance de qualités répondant aux normes assurantielles. Chaque site est unique et est soumis à des contraintes particulières, c'est pourquoi chaque client fait part de ses consignes spécifiques que l'entreprise applique avec la plus grande rigueur. Les données sont réceptionnées dans les 3 centres de télésurveillance en France et immédiatement traitées par les opérateurs de télésurveillance professionnels. Des rapports de traitements des données des appels et des alarmes et des statistiques sont transmis afin de vous permettre d'analyser l'activité de votre site.

Cyber sécurité	Expertise des opérateurs de télésurveillance	Traitements de l'information dans les centres de télésurveillance
 Nos 4 centres de télésurveillance en France reposent sur une organisation unique sur le territoire, basée sur une infrastructure redondante. En cas de dysfonctionnement majeur d'un de nos centres à la suite d'une situation de crise ou d'une attaque extérieure, les 3 autres prennent le relai afin que les sites protégés soient surveillés sans incidence. Les images réceptionnées, traitées, conservées et transmises via nos centres de télésurveillance professionnels sont protégées (firewall, cryptage des données, accès à distance via VPN). Nous vous garantissons l'intégrité de vos données.	 Tous nos opérateurs de télésurveillance sont des professionnels formés et certifiés qui ont en moyenne 15 ans d'expérience. L'expertise de nos opérateurs de télésurveillance vous garantit un accompagnement dédié et personnalisé. Leur engagement sans faille et leur disponibilité 24h/24 365 jours/an sont les clés de leur efficacité pour répondre à tous vos besoins. En bénéficiant des solutions de télésurveillance professionnelles de STANLEY Security, votre site, votre personnel et vos biens sont assurés d'un niveau de sécurité maximal.	 Chaque site est unique et est soumis à des contraintes particulières, c'est pourquoi chaque client nous fait part de ses consignes spécifiques que nous appliquons avec la plus grande rigueur. Les données sont réceptionnées dans nos centres de télésurveillance en France et immédiatement traitées par nos opérateurs de télésurveillance professionnels. Nous vous transmettons des rapports de traitements des alarmes et des statistiques afin de vous permettre d'analyser l'activité de votre site.

FIGURE 6 – TSV

2.3 La vision du groupe Stanley Security

STANLEY Security est une équipe de professionnels engagés pour protéger vos collaborateurs et vos locaux et sécuriser ainsi votre avenir. Cela se traduit par une profonde compréhension de vos besoins, de ce qui est précieux pour vous, afin de vous accompagner et vous aider à pérenniser vos activités. Des conseillers commerciaux aux chefs de projets, en passant par les techniciens et les équipes administratives, tous les membres de STANLEY Security sont animés par cette ambition. Notre volonté d'être un partenaire commercial innovant et proactif exige un leitmotiv commun, des connaissances pointues et de l'expérience. Grâce à une culture de collaboration ouverte avec ses clients et partenaires, l'entreprise aujourd'hui propose un service d'excellence globale qui protège votre présent et construit votre avenir.



FIGURE 7 – Stanley Security en France

2.3.1 Les activités du groupe Stanley Security :

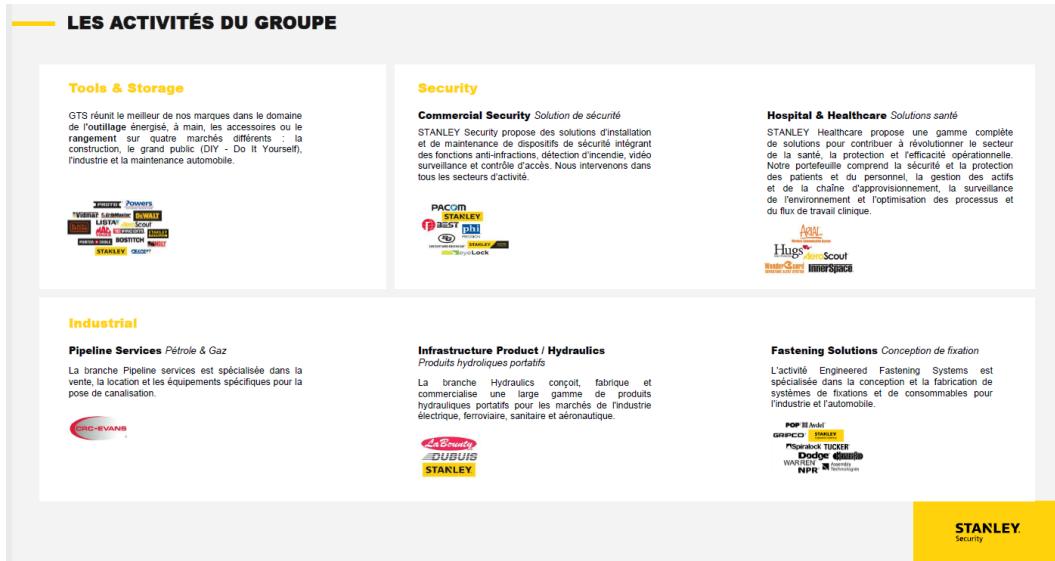


FIGURE 8 – Les activités de Stanley Security

Les équipes du groupe Stanley Security conçoivent, installent et maintiennent des solutions de sécurité adaptées à votre métier pour lutter contre l'intrusion, l'incendie, le vol, le vandalisme, les agressions et les actes de malveillance. La priorité est l'intégration et l'interopérabilité de ces

technologies de sécurité.

Ces solutions de sécurité vous permettent de disposer de la bonne information en temps réel pour prendre la bonne décision et gérer votre sécurité. STANLEY Security est une équipe de professionnels engagés pour protéger vos collaborateurs et vos locaux et sécuriser ainsi votre avenir. Cela se traduit par une profonde compréhension de vos besoins, de ce qui est précieux pour vous, afin de vous accompagner et vous aider à pérenniser vos activités. Des conseillers commerciaux aux chefs de projets, en passant par les techniciens et les équipes administratives, tous les membres de STANLEY Security sont animés par cette ambition. Notre volonté d'être un partenaire commercial innovant et proactif exige un leitmotiv commun, des connaissances pointues et de l'expérience. Grâce à une culture de collaboration ouverte avec ses clients et partenaires, l'entreprise aujourd'hui propose un service d'excellence globale qui protège votre présent et construit votre avenir.

2.3.2 Engagement du groupe pour un avenir durable

NOTRE ENGAGEMENT POUR UN AVENIR DURABLE

Chez Stanley Black & Decker le développement durable est au cœur de notre stratégie : conception, fabrication, distribution, services etc. Chaque jour nous travaillons à améliorer nos services et nos produits. Nous visons aussi à développer notre contribution en faveur des communautés qui nous entourent. Enfin nous sommes attentifs à notre engagement envers l'ensemble de nos parties prenantes en favorisant un dialogue ouvert ayant pour but l'amélioration continue de nos solutions.

Plusieurs fois récompensés pour nos efforts en matière de respect de l'environnement, nous mettons un point d'honneur à favoriser une culture d'entreprise favorable au développement de notre approche ECOSMART.

ECOSMART souligne notre engagement en faveur d'un avenir durable.



ECOSMART

"Nous travaillons, exploitons, concevons, fabriquons, commercialisons, vendons, transportons nos produits en faisant du développement durable la pierre angulaire de notre stratégie. Nous avons fait de la responsabilité sociale une priorité absolue au sein de notre Groupe."

 **Jim Loree**
Président et CEO
Stanley Black & Decker, Inc.



STANLEY
Security

FIGURE 9 – Engagement de Stanley Security

Chez Stanley Black et Decker le développement durable est au cœur de leur stratégie : conception, fabrication, distribution, services etc. Chaque jour l'entreprise travaille à améliorer ses services et ses produits. Il vise aussi à développer sa contribution en faveur des communautés qui leurs entourent. Enfin Stanley est attentifs à ses engagement envers l'ensemble de nos parties prenantes en favorisant un dialogue ouvert ayant pour but l'amélioration continue de nos solutions. Plusieurs fois récompensés pour nos efforts en matière de respect de l'environnement.

2.3.3 Quelques stratégies :



FIGURE 10 – visiongroupe strategie

Stanley Security veut être reconnu comme le leader sur le marché de la sécurité Electronique. A ce titre, pour l'entreprise veut influencer le marché, être reconnu par ses salariés, ses clients, ses concurrents et partenaires comme une entreprise attractive, innovante, fiable, rapide, agile et exemplaire en matière de Responsabilité sociétale des entreprises (RSE). En effet la RSE est la prise en compte par les entreprises, sur base volontaire, et parfois juridique, des enjeux environnementaux, sociaux, économiques et éthiques dans leurs activités.

3 Le projet : Outils de prediction sur la volumetrie des appels et des alarmes

3.1 Revue de la litterature

En 1976 Box et Jenkins proposent une technique d'analyse très efficace sur les séries chronologique qui est largement utilisées dans la littérature à cause de la pertinence des prévisions à court terme. Cette technique d'analyse des séries temporelles est connue sous le nom de ARIMA ou AR représente le terme autorégressif soit les valeurs passées de la série, le terme MA désigne les valeurs passées des résidus et I quant à lui réfère à une transformation de la série qui consiste à retrancher des valeurs passées des valeurs contemporaines. Cette méthode se fait en quatre étapes :

- identification ;
- estimation ;
- test de diagnostic ;
- prévision

1. Processus Auto régressif

$$y_t = \mu + \phi_1 y_{(t-1)} + \phi_2 y_{(t-2)} + \phi_3 y_{(t-3)} + \varepsilon_t$$

Supposent que chaque point peut être prédit par la somme pondérée d'un ensemble de points précédents, plus un terme aléatoire d'erreur.

2. Integrated (Ordre de différenciation)

Le processus d'intégration suppose que chaque point présente une différence constante avec le point précédent.

$$y_t - y_{t-1} = \mu + \varepsilon_t$$

3. MA: Processus Moyenne Mobile

$$y_t = \mu - \theta_1 \varepsilon_{(t-1)} - \theta_2 \varepsilon_{(t-2)} - \theta_3 \varepsilon_{(t-3)} + \varepsilon_t$$

Les processus de moyenne mobile supposent que chaque point est fonction des erreurs entachant les points précédents, plus sa propre erreur.

FIGURE 11 – ARIMA :Autoregressive Moving Average

Ils ont mis en évidence chacune de ces étapes selon que ce processus à mettre en place est autorégressive, intègre ou moyenne mobile en faisant des analyses sur la fonction d'autocorrélation. D'autres éléments sont aussi à considérer comme le fait que la série doit être stationnaire et les résidus du modèles doivent pas être corrélés.

Beaucoup d'articles utilisent la technique de la méthode ARIMA en identifiant des modèles simples et complexes. En effet, Nijdam (1990) soulève la pertinence et l'adéquation de cette technique en particulier si une tendance est persistante au niveau des données. Il identifie un ensemble de limites principalement si la tendance ou la variation des données sont dues à des changements systématique et explicites. Il privilégie dans ce cas l'usage des modèles économétriques. Il mentionne que ces deux techniques peuvent être complémentaire et que leur combinaison correspond aux modèles autorégressifs vectoriels (VAR). Nijdam présente une application directe de la technique de Box-Jenkins sur des données de télécommunications mensuelles. Il identifie un modèle SARIMA après avoir lissé les données en prenant une première et une douzième différence. L'auteur utilise une validation hors échantillon pour estimer et prévoir ses données.

Nous évaluons d'abord les modèles estimés avec toutes les observations, sur la base de la fonction d'autocorrélation de leurs résidus. Ces derniers doivent remplir la condition d'une série bruit blanc. Nous examinons et nous vérifions la pertinence de ces coefficients. Nous accordons une importance relative au critère d'Akaike pour effectuer un choix entre nos modèles. Toutefois, nous ne négligeons pas le fait qu'un modèle ayant le critère le plus faible ne fournit pas nécessairement les meilleures prévisions.

Concernant, les prévisions, nous générerons une série de statistique pour mesurer leurs performances. Nous calculons l'erreur absolue moyenne en pourcentage (MAPE), la racine carré de l'erreur quadratique moyenne (RMSE) et la statistique de Theil.

3.2 Contexte et objectifs

Une logique de prédiction aussi appelé prévision décisionnelle, repose sur l'usage d'outils d'analyse de données présentes ou passées.

Le machine learning est un champ d'étude de l'intelligence artificielle qui se fonde sur des approches mathématiques et statistiques pour donner aux ordinateurs la capacité d'« apprendre » à partir des données. Ces techniques sont souvent d'autant plus efficaces qu'il y a de données. En effet ces outils permettent une projection dans l'avenir et de mieux prendre de meilleures décisions pour assurer leur pérennité. Il est toujours aussi important d'évaluer ses effets directes et indirectes et donc prévoir avec plus d'exhaustivité possible les risques de sa réalisation. Durant l'année 2019, on remarque un fort pic du nombre d'alarmes sur les mois de juin et juillet par rapport au reste de l'année. Ce pic est résumé quantitativement dans le tableau suivant : On remarque un ainsi une

Mois	Mai	Juin	Juillet	Août
Nombre d'alarmes	229 898	250 357	263887	225853
Variation par rapport au mois précédent	N/A N/A	+20 459 +8.9%	+13530 +5.4%	-38 034 -15%

FIGURE 12 – La contribution de ces alarmes au pic total

chute de 38 000 entre juillet et août ce qui représente une variation relative d'environ 15% ce qui est considérable. Nous avons proposé une explication à ce pic en se basant sur les volumétries des différents types d'alarmes (colonne « descr » des bases de données) afin de dégager des facteurs

explicatifs. C'est dans ce sillage que le groupe Stanley Security ont voulu développer un outil de pré-diction user friendly sur la volumétrie des alarmes et des appels entrant dans le monitoring. Le but de cet outil est de pouvoir permettre aux utilisateurs de pouvoir savoir en fonction de la granularité horaire le nombre d'appels et d'alarmes par type de client, groupe de compétence. Ces informations permettront au groupe de redimensionner leur équipe d'opérateur téléphoniques et d'anticiper les effets d'une décision sans les subir. Dans le cadre de notre analyse de la volumétrie des alarmes et des appels entrants, les données sont importantes ce qui permet une prédition efficace de l'évolution de la volumétrie.

3.3 Etude & Conception

3.3.1 Preparation des données

Dans cette partie le but est de charger les données sur la volumétrie des alarmes et la volumétrie des appels entrant dans le monitoring, de les formater pour les rendre analysable et de filtrer les valeurs incohérentes. Nous avons fait particulièrement attention au plage horaire, de régularité temporelle et de remplissage des données manquante. En effet dans une analyse de données classiques les valeurs incohérentes sont simplement supprimées, ici il convient de les remplacer pour préserver un temps régulier entre les points de la série. Les données sur la volumétrie des alarmes et des appels entrant que nous avons sont déjà bien préparer en amont avant d'être explorer. La phase preprocessing (traitement des données) sur les données d'alarmes et d'appels se font chaque semaine en regardant la distribution des données et en fonction de cela on remplace les données aberrantes soit par la moyenne, par la médiane ou par 0. Dans notre cas de figure les données que nous avions étaient déjà bien préparer en amont par l'administrateur de la base de données. Par contre j'ai pris le soin d'expliquer et de prendre en compte le cas où on a des données manquantes comment ou aberrantes pour que l'outils puisse fonctionner dans tous les cas de figure.

Voici nos données brute que nous avions au début avant analyse et exploration des data.

Volumetrie des Alarmes

	Date	Type_Client	PEC_STATION	Type	PEC_emp_no
0	2018-01-01 00:00:00	KA		V P3	6748
1	2018-01-01 00:00:01	SMB		V P3	6733
2	2018-01-01 00:00:01	KA		B P3	6810
3	2018-01-01 00:00:01	KA		I P3	16
4	2018-01-01 00:00:01	KA		B P3	6809

FIGURE 13 – Données brute de la volumetrie des Alarmes

Volumetrie des Appels

Nom_agent	Fonction	Jour	Journée	T_jour	Grpe/Compét.	moy. appel ACD	Temps ACD	Temps ACW	Temps sonnerie agent	Temps en Autre	Temps en AUX	Temps dispo.	Temps connecté	Appels aban.	Date	Appels ACD		
BAGUETTE Sébastien	OP	16	Lundi	Ouvré		NaN	85.933334	...	1289	6010	142	7	1647	5839	14934	NaN	2020-03-16	15
ASZECOWSKI Maud	OP	16	Lundi	Ouvré		NaN	67.341461	...	2761	693	821	61	25187	13883	43406	NaN	2020-03-16	41
BRENA Harry	CO	16	Lundi	Ouvré		NaN	86.042557	...	4044	864	838	64	11730	11845	29385	NaN	2020-03-16	47
AUS Thiphanie	CO	16	Lundi	Ouvré		NaN	36.166668	...	434	180	195	11	16604	5379	22803	NaN	2020-03-16	12
LEMENT Ingrid	OP	16	Lundi	Ouvré		NaN	63.083332	...	757	345	148	137	3042	10295	14724	NaN	2020-03-16	12

FIGURE 14 – Données brute de la volumetrie des Appels

3.3.2 Explorations des données de la volumetrie des appels et des alarmes

Dans cette partie nous allons répondre aux questions suivantes :

- La série est-elle stationnaire ?
- La série est-elle périodique ?
- La périodicité est-elle journalière, hebdomadaire ou annuelle ?

Définition — Soit un processus temporel à valeurs réelles et en temps discret Z_1, Z_2, \dots, Z_t . Il est dit stationnaire au sens faible (ou « de second ordre », ou « en covariance ») si

$$\begin{aligned} &\bullet E[Z_i] = \mu \quad \forall i = 1 \dots t \\ &\bullet \text{Var}[Z_i] = \sigma^2 \neq \infty \quad \forall i = 1 \dots t \\ &\bullet \text{Cov}[Z_i, Z_{i-k}] = f(k) = \rho_k \quad \forall i = 1 \dots t, \quad \forall k = 1 \dots t \end{aligned}$$

FIGURE 15 – Definition d'une serie stationnaire

Ces questions sont très essentielles pour l'analyse des données et le choix du modèle qui sera utilisé dans le calcul des prédictions en fonction de la granularité horaire et des filtres.

Définition — Une série est stationnaire en tendance si la série obtenue en « enlevant » la tendance temporelle de la série originale est stationnaire.

FIGURE 16 – Definition d'une tendance stationnaire

Data des Appels entrants

Nous avons sur la taille des données 49785 lignes et 27 colonnes sur la volumétrie des appels entrant avec comme typologie de tous nos données alpha numérique.

La figure ci-dessous montre la distribution de l'évolution des appels entrant en fonction de la journée.

L'évolution du nombre d'appels entrant fait référence à une série de points de données indexés dans l'ordre chronologique comme une série temporelle (time series).

Tendance : Mouvement de hause et de baisse des données au cours du temps sur une longue période
Saisonnalité : Variance saisonnière

Bruit : Des pic et des creux à intervalles aléatoire

On constate que les données sont périodiques et présente des saisonnalité mensuelle et journalière. De plus on remarque des pics au mois juillet 2020 dû à des évènements rare de l'entreprise et ensuite

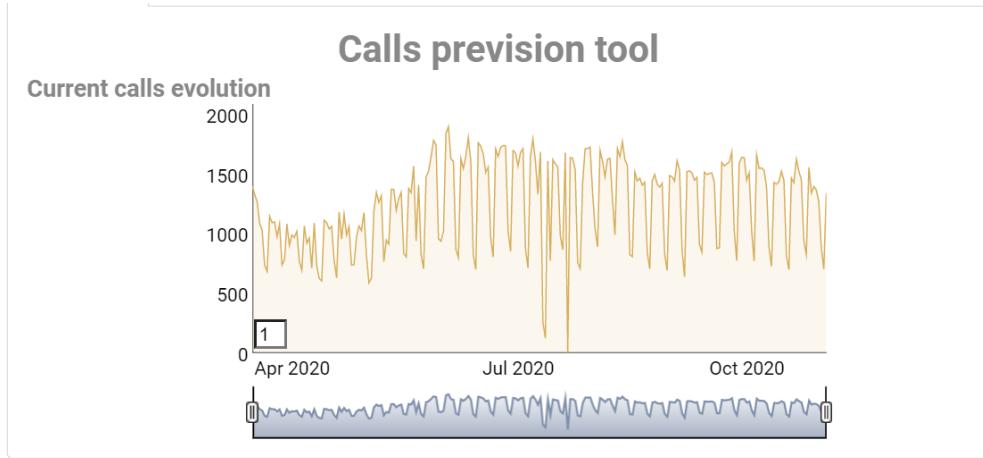


FIGURE 17 – Distribution du nombre d'appels en fonction de la journée

une reprise de la tendance à l'état normale de la périodicité. Le schéma ci-dessous montre clairement l'évolution de ces trois composante de notre série temporelles.

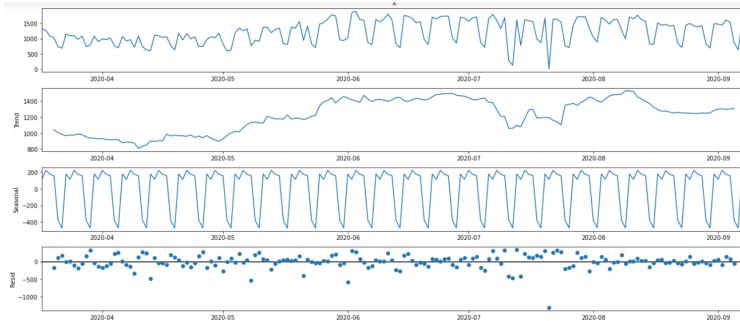


FIGURE 18 – Decomposition of Time Series components

Une application du test de Dickey-Fuller augmenté (ADF) nous montre clairement que la nôtre série est stationnaire. Ce test considère une série stationnaire si la valeur p est faible (selon l'hypothèse nulle) et si les valeurs critiques à des intervalles de confiance de 1%, 5%, 10% sont aussi proche que possible des statistiques de l'ADF.

Comme nous pouvons le voir la statistique ADF n'est pas loin des valeurs critique et la p-value est inférieur au seuil (0.05). D'où notre conclusion que la série sur la volumétrie des appels entrant est stationnaire. Par ailleurs notre série évolue au cours du temps donc nous avons jugé nécessaire d'utiliser SARIMA (Modelé de la Moyenne Mobile Autorégressive Intégré et Saisonnal) qui est un modèle qui rendent les series stationnaire. La différenciation soustrait la valeur actuelle à la valeur précédente et peut être utiliser pour la transformation d'une série temporelle à une série stationnaire. En effet la différenciation du premier ordre traite des tendances linéaire et utilise la transformation $Z_t = Y_t - Y_{t-1}$ et la différenciation du second ordre lui traite des tendances quadratiques.

```

Entrée [20]: result=adfuller(df_appels['Nbre'])
print('statistique ADF :{}'.format(result[0]))
print('p-value :{}'.format(result[1]))
print('valeur critique: ')
for key,value in result[4].items():
    print('\t {}: {}'.format(key,value))

statistique ADF :-41.151562033198815
p-value :0.0
valeur critique:
    1%: -3.4304450929781267
    5%: -2.8615820293961907
    10%: -2.566792370813528

```

FIGURE 19 – Test ADF(Test de Dickey-Fuller-augmenté)

Data des Alarmes

De même sur la volumétrie des alarmes nous avons 436765 lignes et 5 colonnes avec comme typologie de données alpha numérique.

La figure ci-dessous montre la distribution de l'évolution du nombre d'alarmes en fonction du temps. On constate que le nombre augmente au fur et à mesure que la durée augmente excepte le mois d'Aout 2020. Ce phénomène de baisse du nombre d'alarme est dû à une nette amélioration des outils de télésurveillance. L'évolution du nombre d'appels entrant fait référence à une série de points de données indexés dans l'ordre chronologique comme une série temporelle (time series). De plus la série est croissante donc elle n'est pas périodique mais présente une saisonnalité hebdomadaire et journalière.

Une application de la méthode de la statistique roulantes fait qu'on voit clairement que la série n'est pas stationnaire. En effet cette méthode consiste à tracer la moyenne mobile et l'écart-type mobile. La série temporelle est stationnaire si elle reste constante dans le temps c'est-à-dire si les lignes sont droites et parallèles à l'axes des abscisses

Le test ADF ci-dessous ne fait que justifier l'analyse de notre série. Par ailleurs comme nous l'avons si bien dit dans l'autre partie notre série évolue au cours du temps donc nous avons jugé nécessaire d'utiliser SARIMA (Modèle de la Moyenne Mobile Autorégressive Intégré et Saisonnal) qui est un modèle qui rendent les séries stationnaires.

3.3.3 Choix du modèle et des paramètres

Comme nous l'avons dit durant tout le rapport notre choix c'est porter sur le modèle Autorégressive Intégrée saisonnière (SARIMA) car nos données évoluent au cours du temps et peuvent changer en fonction de la période. SARIMA est ajouté juste une différence au modèle ARMA qui s'écrit selon l'équation suivante :

Avec deux parties AR : Autorégressive et MA moyenne mobile. Ce modèle prend en compte les saisonnalités suivantes :

- Hebdomadaire ;
- Mensuelle ;
- Annuelle

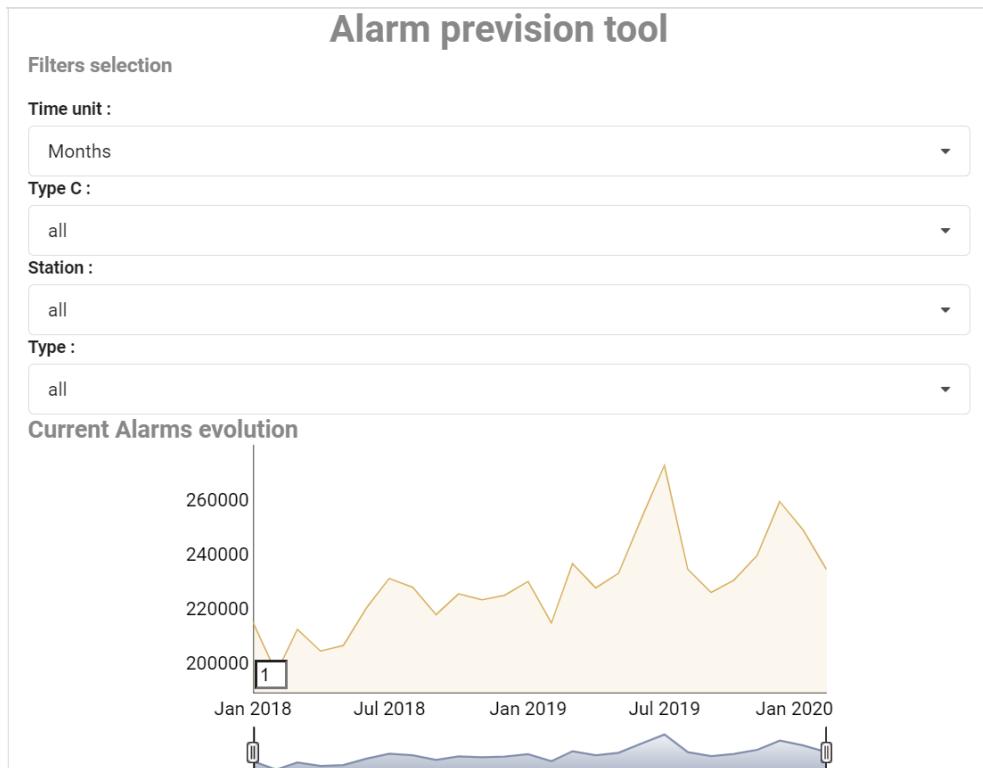


FIGURE 20 – Distribution du nombre d’alarmes en fonction du temps

```

Statistiques ADF : 0.8153688792060544
p-value : 0.9918802434376411
Valeurs Critiques :
    1%: -3.4816817173418295
    5%: -2.8840418343195267
    10%: -2.578770059171598

```

FIGURE 21 – Test ADF sur la volumetrie des alarmes

$$y_t = \beta_1 y_{t-1} + \beta_2 y_{t-2} + \beta_3 y_{t-3} + \dots + \beta_p y_{t-p} + \\ \varepsilon_t + \alpha_1 \varepsilon_{t-1} + \alpha_2 \varepsilon_{t-2} + \dots + \alpha_q \varepsilon_{t-q}$$

FIGURE 22 – Definition du modèle ARMA

De plus il rend les séries stationnaires par ces son terme Intégrée et périodiques.
Par ailleurs pour le choix des paramètres pour le modèle nous utilisons la fonction d’autocorréla-

tion ACF et la fonction d'autocorrélation partielle PACF. L'ACF : Corrélation entre les observations à l'état actuelle et les observations à tous les instants précédent est utiliser pour déterminer le nombre optimal de terme du modèle MA or le nombre de terme détermine l'ordre du modèle. Le PACF sous ensemble de l'ACF quant à lui sert à exprimer les corrélations entre deux observations faites à deux instants dans le temps tout en prenant en compte de l'influence des autres points de données. Nous l'utilisons pour connaitre le nombre optimal de terme AR or le nombre de terme détermine l'ordre du modèle. Nous utilisons ACF PACF pour connaitre le nombre optimal de terme AR or le nombre de terme détermine l'ordre du modèle. Ces paramètres qu'on déterminent sur l'ACF et PACF nous permettent ensuite d'avoir le meilleur modèle avec ses paramètres donnés. Le meilleur modèle avec les paramètres estimés s'obtient en aillant le critère d'information d'Akaike (AIC) le plus faible. Le critère d'information d'Akaike, (en anglais Akaike information criterion ou AIC) est une mesure de la qualité d'un modèle statistique proposée par Hirotugu Akaike en 1973. Lorsque l'on estime un modèle statistique, il est possible d'augmenter la vraisemblance du modèle en ajoutant un paramètre. Le critère d'information d'Akaike, tout comme le critère d'information bayésien, permet de pénaliser les modèles en fonction du nombre de paramètres afin de satisfaire le critère de parcimonie. On choisit alors le modèle avec le critère d'information d'Akaike le plus faible.

Volumetrie des Appels et des alarmes :

```
plot_acf(dd[ 'x' ],lags=70,alpha=0.01)
```

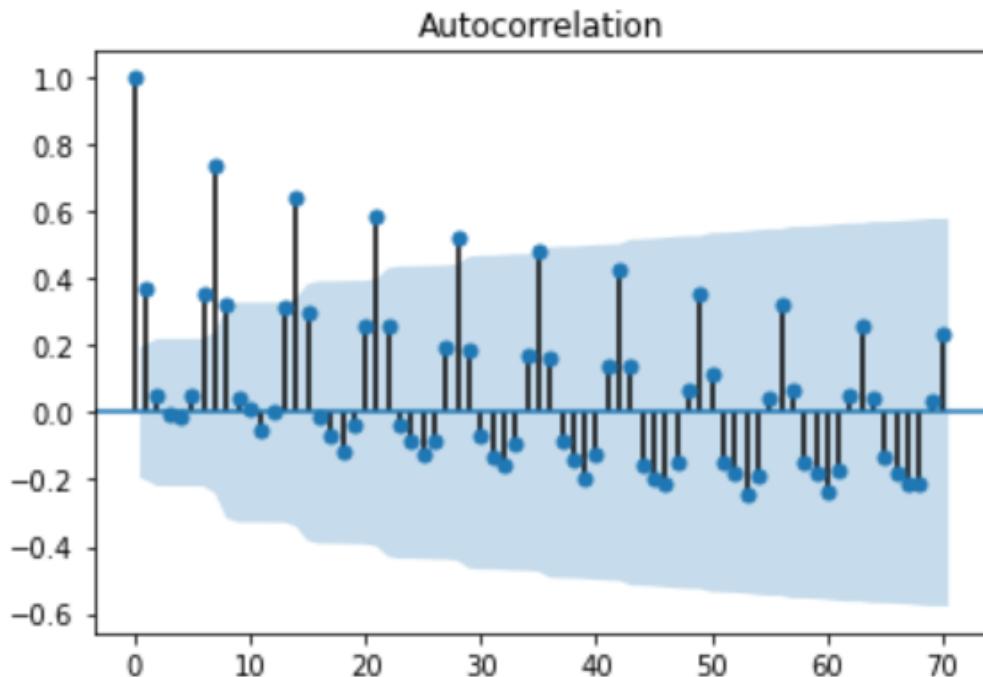


FIGURE 23 – ACF

Cette figure si dessus montre la fonction d'autocorrélation sur les données d'appels au cours du

temps. En effet la bande passante en bleu en est le seuil de signification et ici j'ai pris 70 avec un intervalle de confiance à 90% et les traits verticaux en noir sont les valeurs d'ACF à un moment donné. Seule les lignes qui dépassent la bande passante sont considérées comme significative. Ainsi nous utilisons :

- p = range (0, 4) ;
- d = range(0,1)
- q = range(0, 2) ;
- P = range(0, 3) ;
- D = range(0,1) ;
- Q = range(0, 4)

Ces paramètres obtenue sur les figures ACF et PACF vont nous permettre d'avoir les meilleurs paramètres du modèle.

```
plot_acf(dd['x_1'], lags=70, alpha=0.01)
```

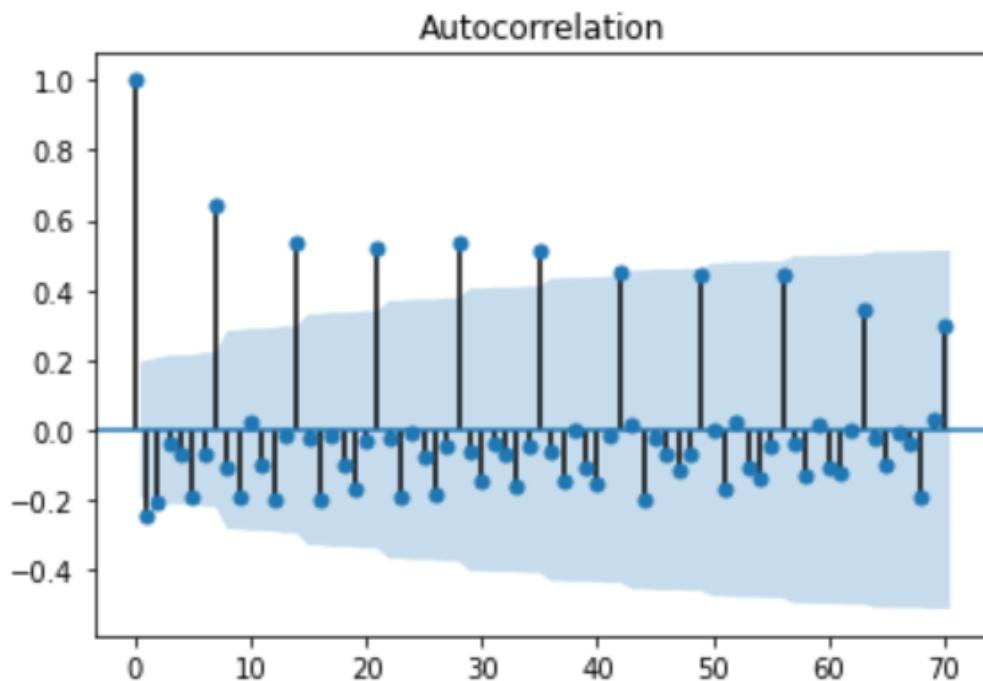


FIGURE 24 – ACF avec une difference de 1

Nous allons voir que ce code ci dessous que nous allons mettre va nous permettre d'avoir l'AIC le plus d'ou le modèle avec les paramètres optimaux.

Conclusion : le modèle optimal pour notre série est ARIMA(2,0,1)*(1,0,3,7) car il l'AIC le plus faible.

Tout ce travail qui a été fait sur la volumétrie des appels est reconduit sur la volumétrie des alarmes.

On constate que notre modèle SARIMA avec nos paramètres optimaux estime bien la série de

```

p = range(0, 4)
d = range(0,1)
q = range(0, 2)

P = range(0, 3)
D = range(0,1)
Q = range(0, 4)

pdq = list(itertools.product(p, d, q))
seasonal_pdq = [(x[0], x[1], x[2], 7) for x in list(itertools.product(P, D, Q))]

res = []
for param in pdq:
    for param_seasonal in seasonal_pdq:
        try:
            mod = sm.tsa.statespace.SARIMAX(series,
                                              order=param,
                                              seasonal_order=param_seasonal,
                                              enforce_stationarity=False,
                                              enforce_invertibility=False)
            results = mod.fit()
            print('ARIMA{}x{} - AIC:{}'.format(param, param_seasonal, results.aic))
            res.append({'params' : 'ARIMA{}x{}'.format(param, param_seasonal), 'aic' : results.aic})
        except:
            continue

```

FIGURE 25 – Choix d’AIC

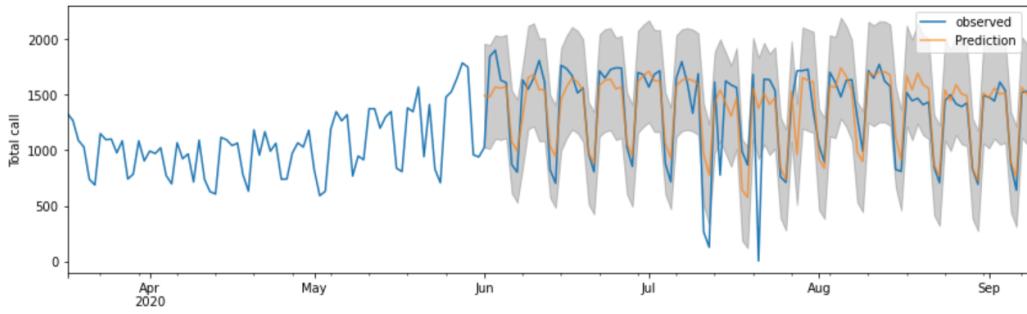


FIGURE 26 – Prediction

donnée des appels mais à du mal à apprendre les pics de données. Un certain nombre d’alarmes sont donc extrêmement sensibles aux conditions météorologiques estivales et présentent des taux de variation supérieurs à 50% durant cette période. Par ailleurs, on peut expliquer l’intensité bien plus importante de ce pic en 2019 qu’en 2018 par la présence d’un pic de chaleur important à la fin de juin / début juillet ce qui correspond au maximum du pic.

		params	aic
67	ARIMA(2, 0, 1)x(1, 0, 3, 7)7	2127.584667	
71	ARIMA(2, 0, 1)x(2, 0, 3, 7)7	2127.588225	
19	ARIMA(0, 0, 1)x(1, 0, 3, 7)7	2137.618342	
43	ARIMA(1, 0, 1)x(1, 0, 3, 7)7	2140.234942	
55	ARIMA(2, 0, 0)x(1, 0, 3, 7)7	2145.097899	
...			
48	ARIMA(2, 0, 0)x(0, 0, 0, 7)7	2605.008938	
24	ARIMA(1, 0, 0)x(0, 0, 0, 7)7	2625.490845	
1	ARIMA(0, 0, 0)x(0, 0, 1, 7)7	2716.088107	
12	ARIMA(0, 0, 1)x(0, 0, 0, 7)7	2822.545219	
0	ARIMA(0, 0, 0)x(0, 0, 0, 7)7	3002.698791	

96 rows × 2 columns

FIGURE 27 – Choix d’AIC optimal

3.4 Bilan

3.4.1 Volumetrie des Alarmes et des alarmes

Nous avons constaté que les données de volumétrie sont assez périodiques ce qui nous a permis d’isoler la technique à utiliser. Afin de prédire le nombre d’alarmes, nous avons donc utilisé une méthode nommée SARIMA, pour Seasonal Auto Regression Integrated Moving Average. Cela distingue trois composantes prépondérantes dans les données. En cherchant la composition optimale de ses trois composantes, nous obtenons un modèle de prédiction efficace. Plus il y a de données, plus cette méthode sera précise. Le modèle donne une prédiction mais aussi un intervalle de confiance à 95% de la prédiction. Le modèle prévoit que les valeurs réelles ont 95% de chances de tomber dans cet intervalle de confiance. La largeur de cet intervalle de confiance diminue lorsque nous augmentons le

nombre de données. Nous avons utilisé la méthode SARIMA pour faire différentes prédictions : des prédictions par mois, par semaine, par jour et par heure. Afin de limiter les calculs, la prédition par heure a été obtenue à partir de la prédition par jour. Nous avons calculé une répartition journalière moyenne des alarmes (pour chaque jour de la semaine de chaque mois) et l'avons appliquée à la prédition journalière.

Les tableaux 48 et 49 en Annexe montrent les résultats des predictions de la volumetrie des alarmes par mois et par jours.

Nous avons calculé le pourcentage des observations qui tombent dans cet intervalle de confiance à 95% donné par la prédition sur les mois de janvier et février 2020. Il faut garder en tête que ce calcul ne se fait que sur 2 points pour les mois.

Nombre d'alarmes	Mois	Semaine	Jour	Heure
Total	100 %	75 %	98,33 %	91,31 %
De priorité P1	100 %	100 %	98,33 %	70,48 %
De priorité P2	100 %	25 %	95 %	87,29 %
De priorité P3	100 %	87,5 %	95 %	82,08 %
De clients KA	100 %	87,5 %	98,33 %	91,45 %
De clients SMB	100 %	87,5 %	98,33 %	86,87 %
De la station B	100 %	0 %	95 %	77,22 %
De la station I	100 %	100 %	98,33 %	82,01 %
De la station V	100 %	87,5 %	96,66 %	84,86 %

FIGURE 28 – Pourcentage des observations de la volumetrie des alarmes

Nous avons calculé l'écart moyen relatif de nos prédictions pour les mois de janvier et février 2020. C'est-à-dire une estimation de l'erreur de nos prédictions.

La prédition est d'autant plus précise que le nombre de données est important. C'est pourquoi la précision de nos modèles va augmenter avec l'ajout de nouvelles données. Néanmoins, les prédictions sur les événements plus rares, comme les prédictions sur les alarmes de priorité P1, est moins précise. On constate que les prédictions sont globalement bonnes mais que le modèle a des difficultés à prévoir les pics ce qui augmente beaucoup l'erreur relative. Les prédictions sur les semaines sont beaucoup moins fiables, elles sont donc à éviter. L'erreur relative sur les heures est plus importante que celle sur les jours car elle utilise un vecteur moyen ce qui ne permet pas une anticipation des pics inhabituels dans une journée. Les données considérées étant de volumétrie moins importante, une erreur de quelques alarmes provoque une erreur relative plus importante. Ainsi, une erreur de quelques alarmes sur les heures creuses induira une plus grande erreur relative. Néanmoins, en pratique, les prédictions sur les heures sont très bonnes. Les erreurs sur les intervalles sont dues au fait que nous avons appliqué un coefficient de proportionnalité pour calculer ces intervalles alors que le calcul réel est beaucoup plus complexe mais nous obtenons néanmoins des résultats très satisfaisant. Finalement, les prédictions sur le long terme sont à faire avec le modèle mensuel, celles sur le moyen terme avec le modèle journalier et celles sur le court terme avec le modèle horaire (tout en gardant en tête qu'elles sont ici obtenues par une répartition moyenne journalière). L'estimation sera d'aut-

Nombre d'alarmes	Mois	Semaine	Jour	Heure
Total	0,053	0,222	0,065	0,101
De priorité P1	0,089	0,108	0,128	0,284
De priorité P2	0,090	0,671	0,083	0,132
De priorité P3	0,017	0,169	0,089	0,156
De clients KA	0,060	0,181	0,057	0,106
De clients SMB	0,083	0,130	0,084	0,139
De la station B	0,125	0,850	0,095	0,165
De la station I	0,099	0,077	0,095	0,178
De la station V	0,0463	0,237	0,102	0,189

FIGURE 29 – Ecart moyen relatif des predictions de la volumetrie des alarmes

tant meilleure que des données seront ajoutées dans le modèle. Il est important de remarquer que des forts pics imprévus ne sont pas bien prédits par les modèles, celui-ci est plus performant sur la prédiction de la variation de la valeur moyenne globale d'alarmes.

Les tableaux 50 et 51 en Annexe nous montrent les résultats obtenus sur les données de la volumétrie des appels par groupe de compétences. Nous avons aussi calculé l'erreur relative à nos prédictions et avons constaté que les prédition sur les mois sont moins précise en journée.

L'erreur

3.4.2 Détermination des patterns des faux-positifs

Nous avons dans un premier temps réalisé une étude préliminaire sur les mois de Janvier et de Février 2020 pour identifier les sites clients à l'origine des faux-positifs. L'objectif était également de cibler précisément les sites avec de mauvaises pratiques qui causent une volumétrie importante d'erreurs. Cette identification permettra à Stanley Security , en complémentarité avec l'étude des erreurs par clustering, de prendre des mesures afin d'améliorer les comportements sur les sites clients et de diminuer le nombre de faux-positifs et ainsi augmenter son efficacité dans son activité. Sur les 2740 sites qui ont présenté des erreurs sur cette période et les 16815 erreurs correspondantes, nous avons extraits 178 sites critiques qui expliquent la majeure partie de ces erreurs, dont les données sont rassemblées dans la deuxième feuille du fichier Excel. Il apparaît que ces sites représentent moins de 5% de la totalité des alarmes traitées par Stanley Security mais sont à l'origine de 8414 erreurs soit 50volumétrie totale des erreurs. Par ailleurs, ces erreurs représentent en moyenne plus de 55% des alarmes émises par ces sites ce qui témoigne de mauvaises pratiques au sein de ces sites. Nous avons donc décidé de nous intéresser plus particulièrement aux alarmes provenant des sites critiques afin de déterminer clairement les axes de travail de ces sites pour réduire leur volumétrie de faux-positifs.

Pour étudier ces sites critiques nous avons décidé d'analyser la répartition moyenne des erreurs sur

une journée. Nous avons utilisé des algorithmes de clustering pour regrouper les id_sites ayant des comportements similaires. Nous avons pu déterminer quatre groupes parmi les id_sites critiques, dont les répartitions horaires des alarmes sont représentées ci-dessous.

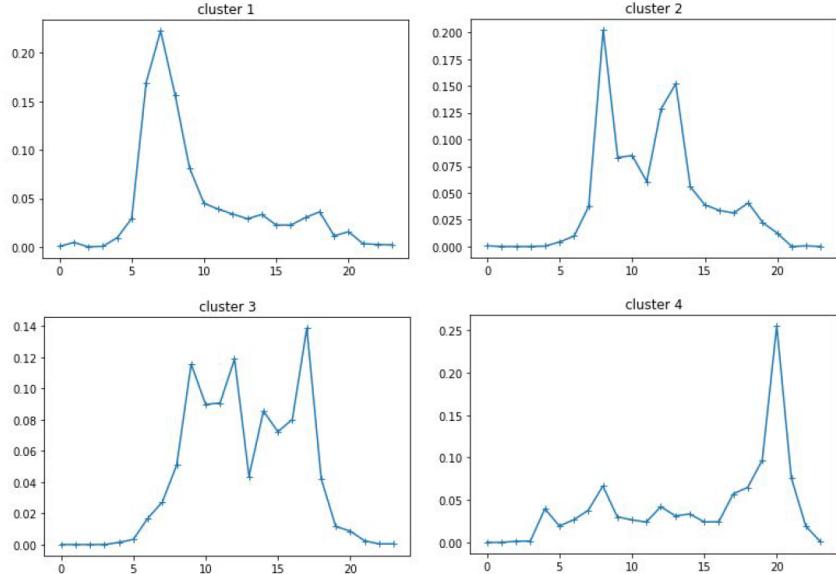


FIGURE 30 – Etude des sites critiques

Nous avons ajouté sur le fichier excel sites_critiques.xlsx le numéro du cluster auquel appartient chaque id_site critique.

- On constate que les id_site du cluster 1 réalisent presque toute leurs erreurs entre 5 et 10 h du matin ce qui correspond vraisemblablement aux ouvertures
- Ceux des clusters 2 et 3 déclenchent principalement des erreurs lors de la journée de travail. On peut supposer qu'elles sont liées à de f ausses manipulations lors des heures de travail.
- Enfin les id_site appartenant au groupe 4 déclenchent la plupart de leurs erreurs vers 20h ce qui correspond à la fermeture et possiblement au passage de personnel de ménage

Le but de cette partie était d'identifier des patterns permettant de distinguer les faux-positifs des autres alarmes. Sur les données de Janvier et Février 2020, nous avons donc effectué un clustering en distinguant chaque jour de la semaine. Après avoir déterminé le nombre optimal de clusters, nous avons pour chaque jour (sauf dimanche) obtenu un cluster avec une proportion importante d'erreurs, les autres clusters ayant des proportions d'erreur inférieures à celle dans les données initiales. Les clusters retenus ont ainsi les caractéristiques suivantes :

On remarque déjà qu'on peut rassembler les clusters en deux groupes selon les patterns identifiés.

1. Clusters de lundi, mardi et samedi :
 - clients KA
 - légère augmentation du taux d'intrusion
 - priorités P1 et P2
 - uniquement station V
2. Clusters de mercredi, jeudi et vendredi :
 - clients KA
 - forte augmentation du taux d'intrusion

	Lundi	Mardi	Mercredi	Jeudi	Vendredi	Samedi	Données initiales
Proportion erreurs (%)	15,3	18,1	8,5	9,69	9,72	10,6	3,5
Nombre erreurs	1520	1734	1153	1685	1649	920	16984
Proportion KA (%)	99,7	100	97,1	93,9	94	99,9	59,5
Proportion intrusion (%)	45,5	46,1	62,3	60,8	63	47,8	38,3
Proportion (%) $300 \leq \text{prio} \leq 320$	63	63	99	98	99	65	53
Proportion (%) $\text{prio} \leq 10$	33	32	0	0	0	32	37
Station majoritaire	V (100%)	V (100%)	B et V	B et V	B et V	V (100%)	B (31,65%) V (24,47%)

FIGURE 31 – Clustering et distinction des positifs et faux-positifs

— priorité P2
 — stations B et V

Les tracés suivants comparent la répartition horaire des clusters avec la répartition totale.

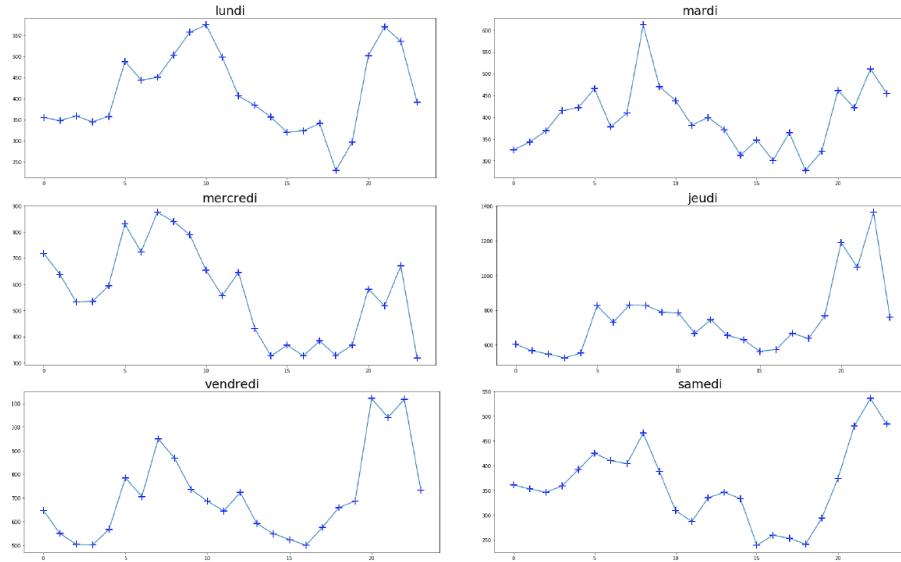


FIGURE 32 – répartition horaire des clusters avec la répartition totale

On retrouve à peu près le même profil que la répartition globale mais le pic du soir (aux alentours

de 20h) est relativement plus important. Cependant, on ne peut pas directement conclure sur la répartition horaire des faux-positifs puisque les clusters construits permettent de les isoler de la plupart des autres alarmes mais ces regroupements ne permettent pas pour l'instant de distinguer d'un nombre important d'alarmes pertinentes.

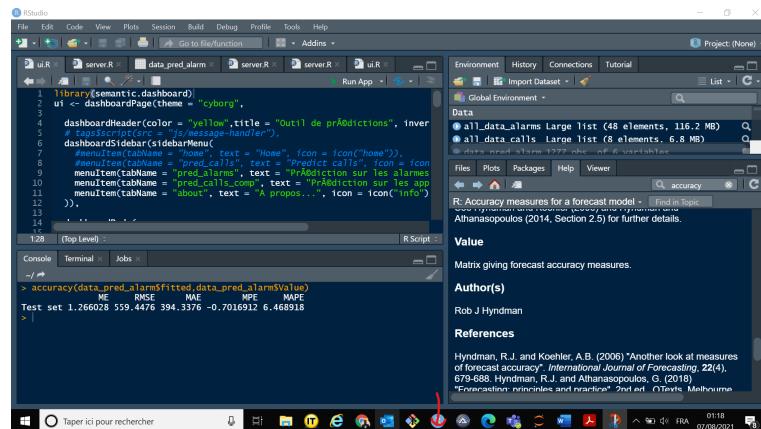
4 Automatisation

4.1 Contexte et objectifs

Dans le contexte actuel de la compétitivité des entreprises, l'automatisation des récurrents devient incontournable pour optimiser de la ressource humaine et du temps. En effet l'automatisation robotiser des processus (RPA) est une technologie de création de robot par apprentissage du comportement d'un utilisateur sur un interface graphique. Le but est de réduire les couts, diminuer les formalités tout en permettant aux équipes de dégager du temps pour se focaliser sur des tâches à valeurs ajoutée telle que le suivi des situations complexes. Dans notre projet la mise à jour des données sur la volumétrie des appels et des alarmes vont se faire de manière automatiser chaque 2 semaine de ce fait on gagnera du temps à faire de manière récurrente les mises à jours chaque deux semaines de manière redondante.

4.2 Conception

Le développement pour l'automatisation de nos process robotise s'est fait en utilisant AutoIt. En effet AutoIt (prononcer aow-toh-it)² est un langage de script freeware permettant de créer des automatisations sous le système d'exploitation Microsoft Windows. le logiciel était principalement destiné à créer des scripts d'automatisation (parfois appelés macros) pour des programmes Microsoft Windows³. De tels scripts ont prouvé leur utilité dans l'automatisation de tâches fortement répétitives, comme le déploiement d'un grand nombre de PC avec des instructions d'installation identiques. Avec les versions successives, AutoIt s'est développé pour inclure des améliorations tant dans la conception du langage de programmation que dans les fonctionnalités générales.



The screenshot shows the RStudio interface with the following R code in the script editor:

```
library(Semantic.dashboard)
ui <- dashboardPage(theme = "cyborg",
  dashboardHeader(color = "yellow", title = "Outil de pr@dictions",
  # tags$script(src = "js/message-handler"),
  dashboardSidebar(debarMenu(
    menuItem(tabName = "home", text = "Home", icon = icon("home")),
    menuItem(tabName = "pred_calls", text = "Predict calls", icon = icon("phone")),
    menuItem(tabName = "pred_alarms", text = "Pr@dition sur les alarmes",
    menuItem(tabName = "pred_calls_comp", text = "Pr@dition sur les appels",
    menuItem(tabName = "about", text = "A propos...", icon = icon("info"))
  )),
  dashboardBody(
    #tags$head(tags$script(src = "js/main.js")),
    #tags$head(tags$script(src = "js/dashboard.js"))
  )
)
#ui
server <- function(input, output, session) {
  output$pred_calls <- renderText({
    pred_calls()
  })
  output$pred_alarms <- renderText({
    pred_alarms()
  })
  output$pred_calls_comp <- renderText({
    pred_calls_comp()
  })
}
shinyApp(ui = ui, server = server)
```

The R console shows the execution of the code and the results of the `accuracy` function:

```
> accuracy(data_pred_alarm$fitted,data_pred_alarm$value)
  ME RMSE MAE MPE MAPE
Test set 1.266028 559.4476 394.3376 -0.7016912 6.468918
> !
```

FIGURE 33 – Etape

L'automatisation ici consiste à faire de manière automatique les images montrées au paravant de manière à automatiser ces tâches récurrentes. Voici le code de la mise à jour automatique via AutoIt.

```

library(syntactic.dashboard)
ui <- dashboardPage(theme = "cyborg",
  dashboardHeader(color = "yellow", title = "Outil de prédictions",
  # tags$script(src = "js/message-handler"),
  dashboardSidebar(menu =
    dashboardMenu("Prédiction", "Prédiction sur les appels", "Prédiction sur les alarmes",
    menuitem(tabName = "pred_calls", text = "Predict calls", icon = icon("phone")),
    menuitem(tabName = "pred_alarms", text = "Prédiction sur les alarmes", icon = icon("alarm")),
    menuitem(tabName = "about", text = "A propos...", icon = icon("info"))
  )),
  dashboardBody(tabItems(
    tabItem(tabName = "pred_calls", text = "None", icon = icon("phone")),
    tabItem(tabName = "pred_alarms", text = "Predict calls", icon = icon("alarm")),
    tabItem(tabName = "about", text = "A propos...", icon = icon("info"))
  ))
)

```

FIGURE 34 – Etape 2

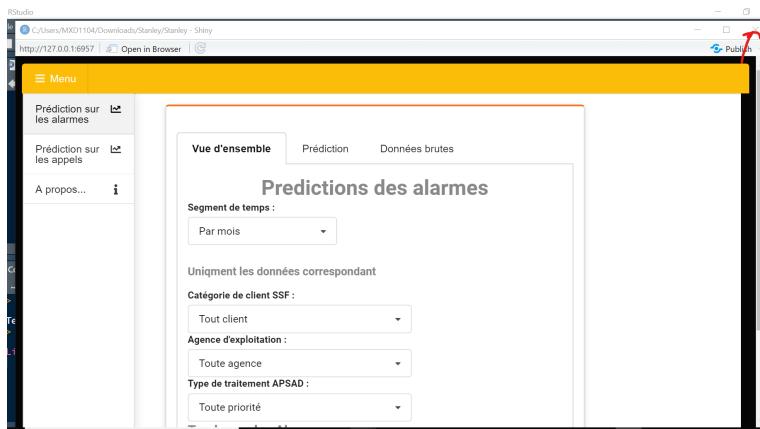


FIGURE 35 – Etape 3

```

options(shiny.maxRequestSize=2000*1024^2) # max 2000Mo pour upload file
source("../src/R/functions.R")
source("../src/R/dataCalls.R")
source("../src/R/dataAlarms.R")

max_prev_period < 30
server <- function(input, output, session) {
  output$date_range_alarm <- renderUI({
    req(input$time)
    dateRangeInput("date_range_alarm", input$time)
  })
}

shiny::runApp(server, port = 3225)

```

FIGURE 36 – Etape 4

5 Conclusion

Dans l'industrie des centres d'opérateurs de télésurveillances, la prévision du volume des appels et des alarmes est indispensable. En effet la volumétrie des appels et des alarmes orientent la planification du personnel nécessaire à l'activité du centre d'opérateur de télésurveillance. La sur-estimation et la sous-estimation de ces opérateurs induit des à des pénalités et des couts considérables. Par conséquent, une prévision précise du volume des appels et des alarmes minimisent le risque de sur ou de sous estimer les ressources requises. L'objectif de ce mémoire est de prédire la volumétrie du nombre d'appel et d'alarme en fonction de la granularité horaire. Pour ce faire nous avons exploré le modèle SARIMA basé sur la technique de Box et Jenkins avec les adaptations nécessaires. Nous avons évalué le résultat de nos prévisions par la mesure du pourcentage de l'erreur des prévisions et les intervalles de prévisions qui leurs sont associés. Ce résultat montre que le modèle SARIMA qu'on a utilisé s'adapte à l'industrie des centres d'opérateurs de télésurveillances plutôt volatile et saisonnière. En effet au fur et à mesure nos données augmentent le modèle s'améliore à donner des prédictions beaucoup exacte. Par ailleurs selon plusieurs articles les auteurs ne considèrent pas l'éventualité de différencier la série à prévoir malgré la présence possible non-stationnaire. On constate que les prédictions sont globalement bonnes mais que le modèle a des difficultés à prévoir les pics ce qui augmente beaucoup l'erreur relative. Les prédictions sur les semaines sont beaucoup moins fiables, elles sont donc à éviter. L'erreur relative sur les heures est plus importante que celle sur les jours car elle utilise un vecteur moyen ce qui ne permet pas une anticipation des pics inhabituels dans une journée. Les données considérées étant de volumétrie moins importante, une erreur de quelques alarmes provoque une erreur relative plus importante. Ainsi, une erreur de quelques alarmes sur les heures creuses induira une plus grande erreur relative. Néanmoins, en pratique, les prédictions sur les heures sont très bonnes. Grâce à l'utilisation du clustering, les causes de ces pratiques ont été identifiées et devraient permettre à Stanley Security de collaborer avec ces sites clients pour ajuster leurs pratiques et éviter des déclenchements intempestifs d'alarmes. L'utilisation du clustering a également permis de détecter des patterns pour ces faux-positifs : clients KA avec des priorités P2, qui concernent surtout les stations B et V, et correspondent majoritairement à des intrusions. Cependant, le caractère faiblement discret des paramètres et la volumétrie importante des alarmes reçues par Stanley Security ne permettent pas d'établir des critères discriminants pour identifier et anticiper les faux-positifs, si bien que les patterns dégagés ne permettent que d'isoler un sous-groupe d'alarmes où la possibilité d'avoir des erreurs parmi ces alarmes est plus élevée.

Références

- [21] Barczy M., Ben Alaya M., Kebaier A. and Pap G. *Asymptotic behavior of maximum likelihood estimators for a jump-type Heston model* 2019
- [22] Barczy M., Ben Alaya M., Kebaier A. and Pap G. *Asymptotic behavior of maximum likelihood estimators for a jump-type Heston model* 2019
- [23] Barczy M., Ben Alaya M., Kebaier A. and Pap G. *Asymptotic behavior of maximum likelihood estimators for a jump-type Heston model* 2019
- [24] Barczy M., Ben Alaya M., Kebaier A. and Pap G. *Asymptotic behavior of maximum likelihood estimators for a jump-type Heston model* 2019
- [25] Barczy M., Ben Alaya M., Kebaier A. and Pap G. *Asymptotic behavior of maximum likelihood estimators for a jump-type Heston model* 2019
- [26] Barczy M., Ben Alaya M., Kebaier A. and Pap G. *Asymptotic behavior of maximum likelihood estimators for a jump-type Heston model* 2019
- [27] Barczy M., Ben Alaya M., Kebaier A. and Pap G. *Asymptotic behavior of maximum likelihood estimators for a jump-type Heston model* 2019
- [28] Barczy M., Ben Alaya M., Kebaier A. and Pap G. *Asymptotic behavior of maximum likelihood estimators for a jump-type Heston model* 2019
- [29] Barczy M., Ben Alaya M., Kebaier A. and Pap G. *Asymptotic behavior of maximum likelihood estimators for a jump-type Heston model* 2019
- [30] Barczy M., Ben Alaya M., Kebaier A. and Pap G. *Asymptotic behavior of maximum likelihood estimators for a jump-type Heston model* 2019
- [31] Barczy M., Ben Alaya M., Kebaier A. and Pap G. *Asymptotic behavior of maximum likelihood estimators for a jump-type Heston model* 2019
- [32] Barczy M., Ben Alaya M., Kebaier A. and Pap G. *Asymptotic behavior of maximum likelihood estimators for a jump-type Heston model* 2019
- [33] Barczy M., Ben Alaya M., Kebaier A. and Pap G. *Asymptotic behavior of maximum likelihood estimators for a jump-type Heston model* 2019
- [34] Barczy M., Ben Alaya M., Kebaier A. and Pap G. *Asymptotic behavior of maximum likelihood estimators for a jump-type Heston model* 2019
- [35] Barczy M., Ben Alaya M., Kebaier A. and Pap G. *Asymptotic behavior of maximum likelihood estimators for a jump-type Heston model* 2019
- [36] Barczy M., Ben Alaya M., Kebaier A. and Pap G. *Asymptotic behavior of maximum likelihood estimators for a jump-type Heston model* 2019
- [37] Barczy M., Ben Alaya M., Kebaier A. and Pap G. *Asymptotic behavior of maximum likelihood estimators for a jump-type Heston model* 2019
- [38] Barczy M., Ben Alaya M., Kebaier A. and Pap G. *Asymptotic behavior of maximum likelihood estimators for a jump-type Heston model* 2019
- [39] Barczy M., Ben Alaya M., Kebaier A. and Pap G. *LL Bean Improves Call-center Forcasting* 1995
- [40] Andrews, BH and Shawn M.Cunningham *Asymptotic behavior of maximum likelihood estimators for a jump-type Heston model* 2019
- [41] Barczy M., Ben Alaya M., Kebaier A. and Pap G. *Asymptotic behavior of maximum likelihood estimators for a jump-type Heston model* 2019

- [42] Barczy M., Ben Alaya M., Kebaier A. and Pap G. *Asymptotic behavior of maximum likelihood estimators for a jump-type Heston model* 2019
- [43] Barczy M., Ben Alaya M., Kebaier A. and Pap G. *Asymptotic behavior of maximum likelihood estimators for a jump-type Heston model* 2019

Annexe

Impact des tempêtes sur les volumétries d'alarmes :

Nous avons également essayé de dégager une corrélation entre l'intervention d'une tempête et une augmentation de la volumétrie d'alarmes. Nous avons donc comparé les données en temps normal, aux données en temps de tempête. Si dans certains cas nous avons relevé une augmentation de 11% en moyenne, certaines tempêtes n'ont eu aucune conséquence sur la volumétrie d'alarmes. Ceci s'explique par la répartition géographique des activités de Stanley Security qui ne coïncide pas forcément avec la localisation de la tempête. Cependant, l'absence de données géographiques dans les bases de données fournies n'a pu permettre d'établir d'autre conclusion qu'une potentielle augmentation de 10% du nombre d'alarmes suite à des fortes pluies, chutes de neige ou à une tempête dans une zone d'activités de Stanley Security.

Outil de prediction :

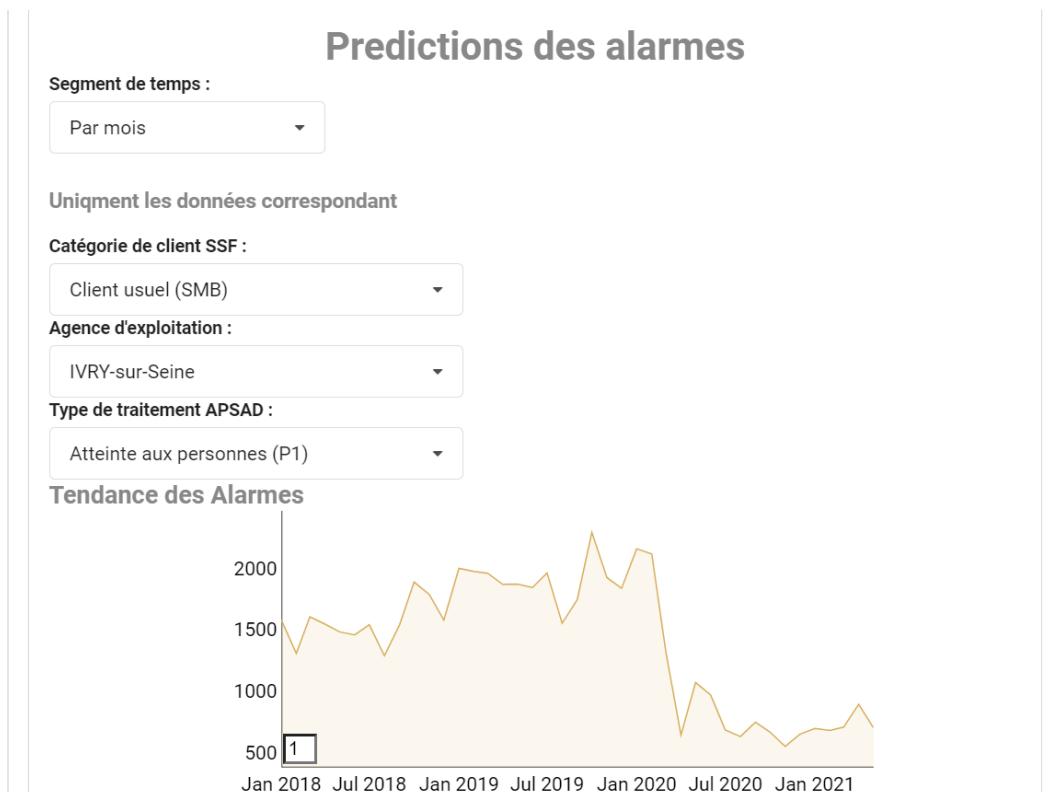


FIGURE 37 – Tendance des données d'alarmes par mois

Alarm prevision tool

Filters selection

Time unit :

Days

Type C :

SMB

Station :

V

Type :

P2

Current Alarms evolution

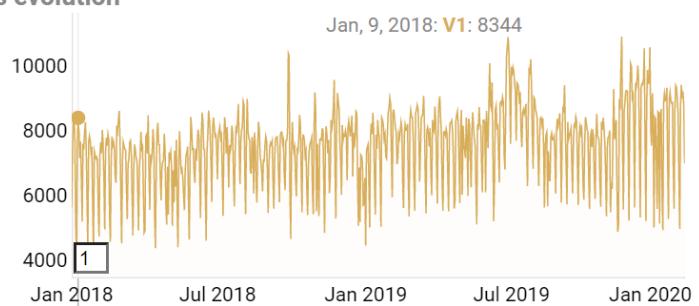


FIGURE 38 – Tendance des données d'alarmes par client SMB par type p1 par mois

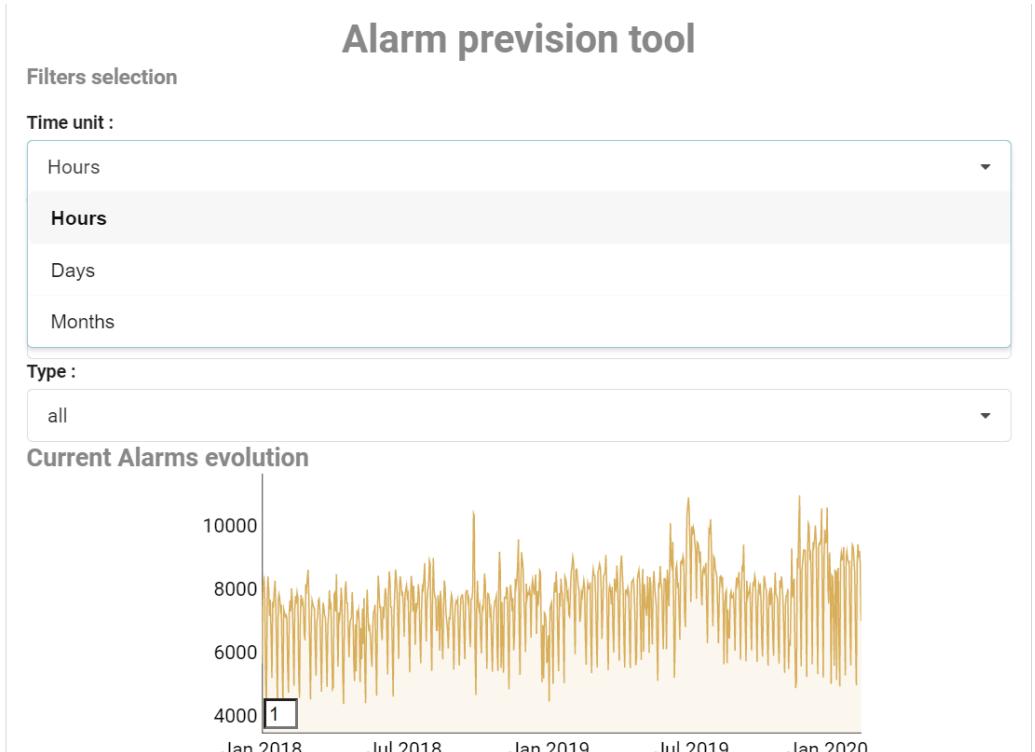


FIGURE 39 – Tendance des données d’alarmes par mois



FIGURE 40 – prediction des données d’alarmes type client KA par type p1 par mois

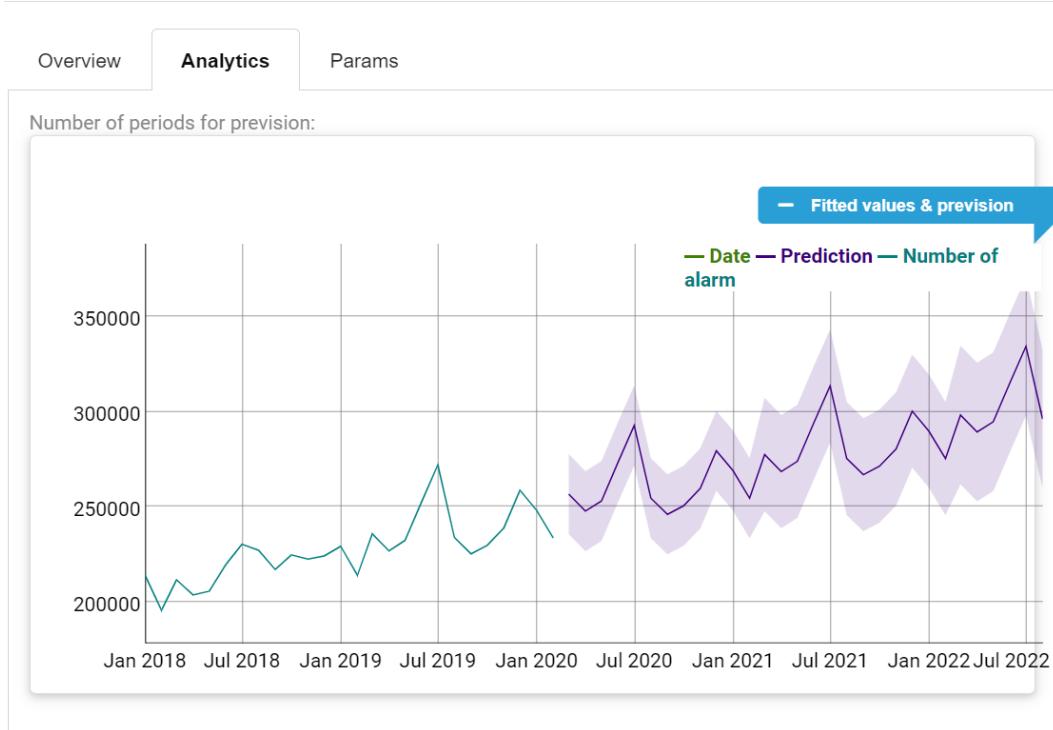


FIGURE 41 – prediction des alarms par mois

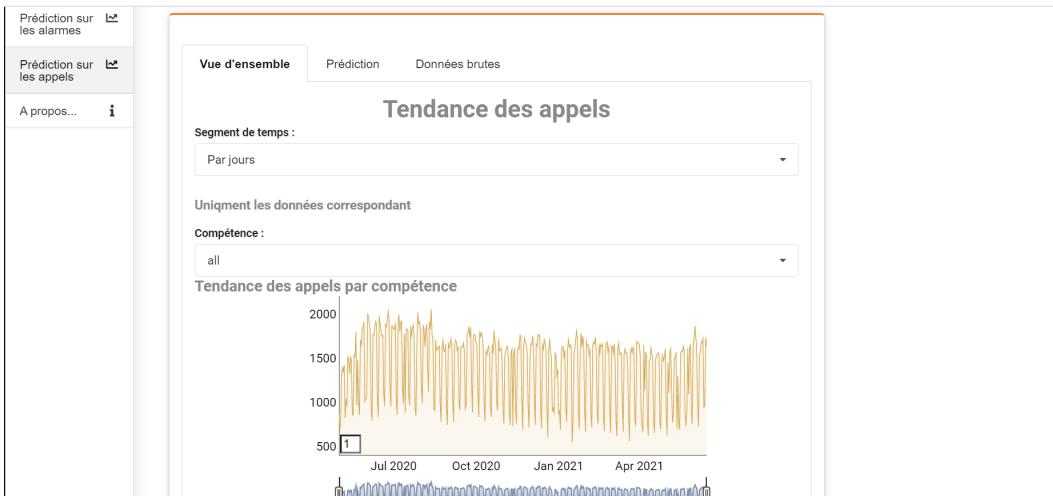


FIGURE 42 – Tendance des données d'appels par mois



FIGURE 43 – Tendance des données d'appels par heure



FIGURE 44 – Tendance des données d'appels du client WesterUnion par jour



FIGURE 45 – Tendance des données d'appels de westernUnion par heure

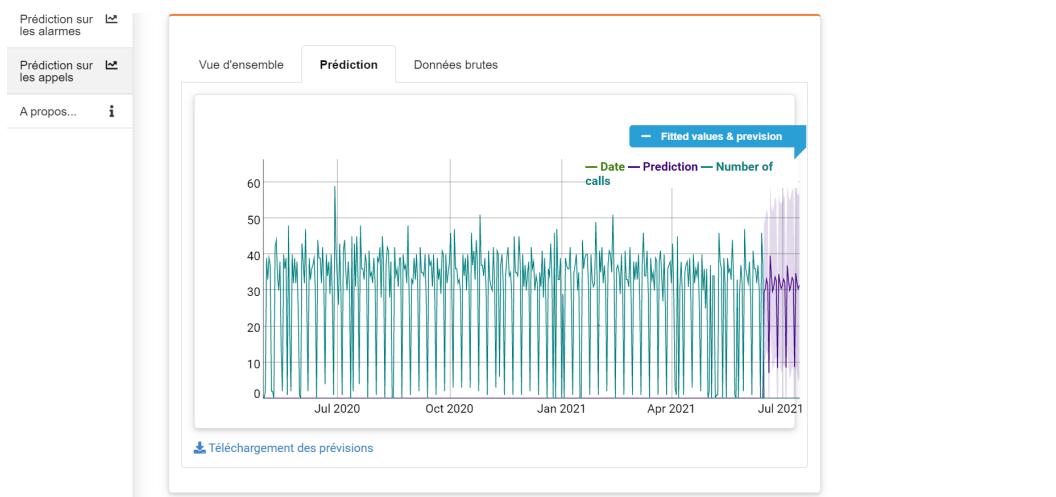


FIGURE 46 – prediction des appels du client westernUnion par jours

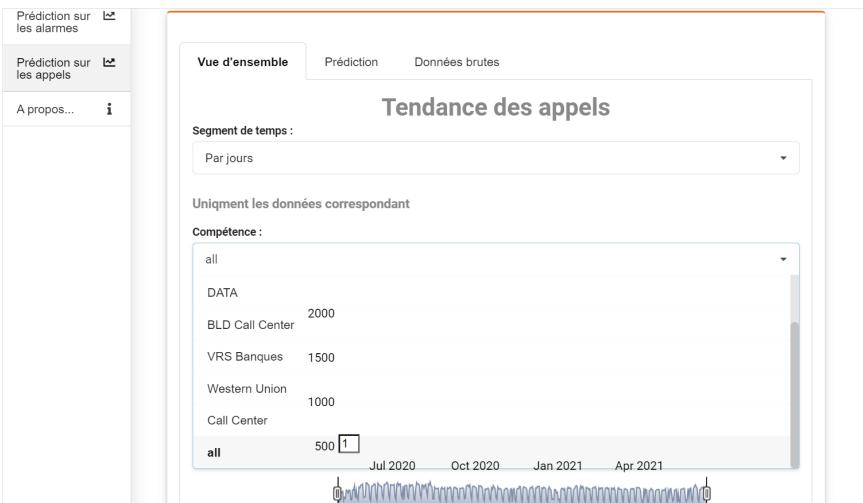


FIGURE 47 – Les filtres des appels dans l’outil



FIGURE 48 – prediction d’appels de tous les clients par jours



FIGURE 49 – prediction des alarmes par type clients KA type P1 par mois

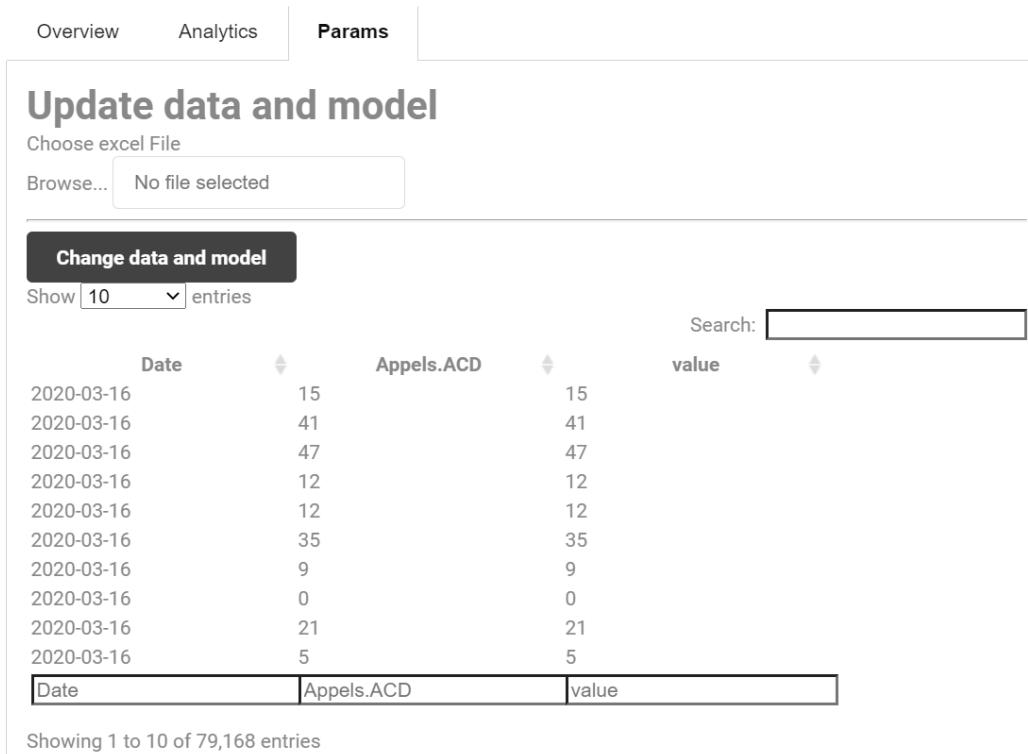


FIGURE 50 – Mise à jours des données

```

1  If Not ProcessExists("RStudio.exe") then
2      Run("C:\Program Files\RStudio\bin\Rstudio.exe")
3      Sleep(60000)
4  EndIf
5
6  $h = WinWait("[REGEXPTITLE:RStudio]", "", 20)
7  If Not $h Then
8      MsgBox(0, "Message", "Pas de fenêtre")
9      Exit
10 EndIf
11
12 ;MsgBox(0,"ou est on","ici")
13
14
15 WinActivate($h)
16
17 $a=WinGetPos($h)
18
19 MouseClick("left",$a[0]+749,$a[1]+121,1,10)
20
21
22
23 Sleep(10000)
24
25 ; on va faire un $h winwait
26
27 ;MsgBox(0,"ou est on","ici 1")
28 $b= WinWait("[REGEXPTITLE:.+ - Shiny]", "", 20)
29
30 ;MsgBox(0,"ou est on","ici "& $b)
31 WinActivate($b)
32
33 sleep(20000)
34
35 Send("!{F4}")
36
37 MouseClick("left",$a[0]+75,$a[1]+657,1,10)
38 Send("Alarms_Upload('./Data/Data_2021M06.csv'){CR}")
39

```

FIGURE 51 – Code Automatisant la mise à jour de nos données

Date	lower	prediction	upper	value
2018/01/01 00:00:00				214415
2018/02/01 00:00:00				195719
2018/03/01 00:00:00				211683
2018/04/01 00:00:00				203764
2018/05/01 00:00:00				205777
2018/06/01 00:00:00				219754
2018/07/01 00:00:00				230450
2018/08/01 00:00:00				227226
2018/09/01 00:00:00				217148
2018/10/01 00:00:00				224798
2018/11/01 00:00:00				222636
2018/12/01 00:00:00				224248
2019/01/01 00:00:00				229341
2019/02/01 00:00:00				214110
2019/03/01 00:00:00				235898
2019/04/01 00:00:00				226982
2019/05/01 00:00:00				232340
2019/06/01 00:00:00				252757
2019/07/01 00:00:00				271967
2019/08/01 00:00:00				233845
2019/09/01 00:00:00				225321
2019/10/01 00:00:00				229790
2019/11/01 00:00:00				238888
2019/12/01 00:00:00				258719
2020/01/01 00:00:00				248268
2020/02/01 00:00:00				233793
2020/03/01 00:00:00	235680,0977	256680,1429	277680,188	
2020/04/01 00:00:00	226764,0977	247764,1429	268764,188	
2020/05/01 00:00:00	232122,0977	253122,1429	274122,188	
2020/06/01 00:00:00	252539,0977	273539,1429	294539,188	
2020/07/01 00:00:00	271749,0977	292749,1429	313749,188	
2020/08/01 00:00:00	233627,0977	254627,1429	275627,188	
2020/09/01 00:00:00	225103,0977	246103,1429	267103,188	
2020/10/01 00:00:00	229572,0977	250572,1429	271572,188	
2020/11/01 00:00:00	238670,0977	259670,1429	280670,188	
2020/12/01 00:00:00	258501,0977	279501,1429	300501,188	
2021/01/01 00:00:00	248050,0977	269050,1429	290050,188	
2021/02/01 00:00:00	233575,0977	254575,1429	275575,188	
2021/03/01 00:00:00	247763,737	277462,2857	307160,834	
2021/04/01 00:00:00	238847,737	268546,2857	298244,834	
2021/05/01 00:00:00	244205,737	273904,2857	303602,834	
2021/06/01 00:00:00	264622,737	294321,2857	324019,834	
2021/07/01 00:00:00	283832,737	313531,2857	343229,834	
2021/08/01 00:00:00	245710,737	275409,2857	305107,834	
2021/09/01 00:00:00	237186,737	266885,2857	296583,834	
2021/10/01 00:00:00	241655,737	271354,2857	301052,834	
2021/11/01 00:00:00	250753,737	47 280452,2857	310150,834	
2021/12/01 00:00:00	270584,737	300283,2857	329981,834	
2022/01/01 00:00:00	260133,737	289832,2857	319530,834	
2022/02/01 00:00:00	245658,737	275357,2857	305055,834	
2022/03/01 00:00:00	261871,2834	298244,4286	334617,574	
2022/04/01 00:00:00	252955,2834	289328,4286	325701,574	
2022/05/01 00:00:00	258313,2834	294686,4286	331059,574	
2022/06/01 00:00:00	278730,2834	315103,4286	351476,574	
2022/07/01 00:00:00	297940,2834	334313,4286	370686,574	
2022/08/01 00:00:00	259818,2834	296191,4286	332564,574	

Date	Value	prediction	lower	upper	fitted				
2018/01/01 00:00:00	5583				5577,417165				
2018/01/02 00:00:00	7345				7337,65533				
2018/01/03 00:00:00	8106				8097,894492				
2018/01/04 00:00:00	8185				8176,815653				
2018/01/05 00:00:00	7626				7618,374813				
2018/01/06 00:00:00	5105				5099,895971				
2018/01/07 00:00:00	4062				4057,939126				
2018/01/08 00:00:00	7580				6156,828744				
2018/01/09 00:00:00	8303				8086,347195				
2018/01/10 00:00:00	7849				8272,012378				
2018/01/11 00:00:00	7054				7914,407593				
2018/01/12 00:00:00	7576				7394,424399				
2018/01/13 00:00:00	6482				5470,725969				
2018/01/14 00:00:00	5141				4470,874529				
2018/01/15 00:00:00	7434				7068,637721				
2018/01/16 00:00:00	7364				8099,762867				
2018/01/17 00:00:00	7870				7914,734865				
2018/01/18 00:00:00	8163				7779,127007				
2018/01/19 00:00:00	7415				7784,763694				
2018/01/20 00:00:00	5937				5773,11429				
2018/01/21 00:00:00	4254				4525,427348				
2018/01/22 00:00:00	7517				6951,980586				
2018/01/23 00:00:00	7747				7960,232195				
2018/01/24 00:00:00	7600				7957,763757				
2018/01/25 00:00:00	7271				7696,98144				
2018/01/26 00:00:00	7394				7371,473849				
2018/01/27 00:00:00	5736				5775,423057				
2018/01/28 00:00:00	4202				4276,391826				
2018/01/29 00:00:00	7279				7001,216098				
2018/01/30 00:00:00	7132				7719,306545				
2018/01/31 00:00:00	7050				7562,825263				
2018/02/01 00:00:00	7110				7321,994697				
2018/02/02 00:00:00	7000				7190,491573				
2018/02/03 00:00:00	5537				5493,485312				
2018/02/04 00:00:00	4680				4113,893788				
2018/02/05 00:00:00	7155				7102,364499				
2018/02/06 00:00:00	7555				7479,831117				
2018/02/07 00:00:00	7222				7590,08551				
2018/02/08 00:00:00	7926				7330,099171				
2018/02/09 00:00:00	7513				7483,927112				
2018/02/10 00:00:00	6461				5743,953596				
2018/02/11 00:00:00	4901				4655,815169				
2018/02/12 00:00:00	7237				7289,797265				
2018/02/13 00:00:00	7659				7680,093924				
2018/02/14 00:00:00	7451				7700,993493				
2018/02/15 00:00:00	7794				7618,578397				
2018/02/16 00:00:00	7622				7539,67525				
2018/02/17 00:00:00	5319				5955,247481				
2018/02/18 00:00:00	4517				4306,400228				
2018/02/19 00:00:00	6983				7184,918754				
2018/02/20 00:00:00	7689				7520,056463				
2018/02/21 00:00:00	7443				7621,945589				
2018/02/22 00:00:00	7535				7566,362977				
2018/02/23 00:00:00	7368				7397,592781				
2018/02/24 00:00:00	6530				5761,022475				
2018/02/25 00:00:00	6330				4807,904432				
2018/02/26 00:00:00	8042				7836,397988				
2018/02/27 00:00:00	7910				8047,885081				
2018/02/28 00:00:00	8255				7913,464418				
2018/03/01 00:00:00	8518				8136,894102				
2018/03/02 00:00:00	7644				7984,986986				
2018/03/03 00:00:00	6042				6198,960978				
2018/03/04 00:00:00	4466				5033,677773				

FIGURE 53 – Tableau predictive des alarmes par jours

Date	Value	prediction	lower	upper	fitted
2020/05/01 00:00:00	39414				39374,586
2020/06/01 00:00:00	47937				39414
2020/07/01 00:00:00	49028				47937
2020/08/01 00:00:00	45874				49028
2020/09/01 00:00:00	44549				45874
2020/10/01 00:00:00	44173				44549
2020/11/01 00:00:00	40041				44173
2020/12/01 00:00:00	42922				40041
2021/01/01 00:00:00	41175				42922
2021/02/01 00:00:00	38632				41175
2021/03/01 00:00:00	42191				38632
2021/04/01 00:00:00	38174				42191
2021/05/01 00:00:00	37408				38174
2021/06/01 00:00:00	21871				37408
2021/07/01 00:00:00		21871	11117,1554	32624,8446	21871
2021/08/01 00:00:00		21871	6662,76717	37079,2328	21871
2021/09/01 00:00:00		21871	3244,79483	40497,2052	21871
2021/10/01 00:00:00		21871	363,310866	43378,6891	21871
2021/11/01 00:00:00		21871	-2175,3275	45917,3275	21871
2021/12/01 00:00:00		21871	-4470,432	48212,432	21871
2022/01/01 00:00:00		21871	-6580,9984	50322,9984	21871
2022/02/01 00:00:00		21871	-8545,4657	52287,4657	21871
2022/03/01 00:00:00		21871	-10390,534	54132,5337	21871
2022/04/01 00:00:00		21871	-12135,642	55877,6424	21871
2022/05/01 00:00:00		21871	-13795,467	57537,4675	21871
2022/06/01 00:00:00		21871	-15381,41	59123,4103	21871
2022/07/01 00:00:00		21871	-16902,538	60644,538	21871
2022/08/01 00:00:00		21871	-18366,202	62108,202	21871
2022/09/01 00:00:00		21871	-19778,461	63520,4609	21871
2022/10/01 00:00:00		21871	-21144,378	64886,3783	21871
2022/11/01 00:00:00		21871	-22468,237	66210,237	21871
2022/12/01 00:00:00		21871	-23753,699	67495,6985	21871
2023/01/01 00:00:00		21871	-25003,922	68745,9217	21871
2023/02/01 00:00:00		21871	-26221,655	69963,6549	21871
2023/03/01 00:00:00		21871	-27409,307	71151,3067	21871
2023/04/01 00:00:00		21871	-28569,002	72311,002	21871
2023/05/01 00:00:00		21871	-29702,627	73444,6268	21871
2023/06/01 00:00:00		21871	-30811,864	74553,8639	21871
2023/07/01 00:00:00		21871	-31898,223	75640,2228	21871
2023/08/01 00:00:00		21871	-32963,063	76705,0633	21871
2023/09/01 00:00:00		21871	-34007,616	77749,6155	21871
2023/10/01 00:00:00		21871	-35032,997	78774,9967	21871

FIGURE 54 – Tableau predictive des appels par mois

Date	Value	prediction	lower	upper	fitted						
2020/05/01 00:00:00	857				856,142822						
2020/05/02 00:00:00	683				682,316643						
2020/05/03 00:00:00	720				719,279463						
2020/05/04 00:00:00	1295				1293,70428						
2020/05/05 00:00:00	1382				1380,61711						
2020/05/06 00:00:00	1334				1332,66493						
2020/05/07 00:00:00	1410				1408,58875						
2020/05/08 00:00:00	806				843,435553						
2020/05/09 00:00:00	1007				749,325752						
2020/05/10 00:00:00	959				828,632066						
2020/05/11 00:00:00	1505				1370,06878						
2020/05/12 00:00:00	1475				1431,0275						
2020/05/13 00:00:00	1313				1337,48326						
2020/05/14 00:00:00	1501				1433,25415						
2020/05/15 00:00:00	1476				920,15313						
2020/05/16 00:00:00	857				964,053388						
2020/05/17 00:00:00	839				816,949309						
2020/05/18 00:00:00	1523				1418,94181						
2020/05/19 00:00:00	1507				1458,70831						
2020/05/20 00:00:00	1788				1386,13738						
2020/05/21 00:00:00	957				1468,57878						
2020/05/22 00:00:00	1469				982,049214						
2020/05/23 00:00:00	979				960,161243						
2020/05/24 00:00:00	843				842,481047						
2020/05/25 00:00:00	1696				1459,40608						
2020/05/26 00:00:00	1642				1516,99911						
2020/05/27 00:00:00	1824				1533,96152						
2020/05/28 00:00:00	1844				1362,45854						
2020/05/29 00:00:00	1901				1300,53978						
2020/05/30 00:00:00	999				1015,35335						
2020/05/31 00:00:00	1023				842,673832						
2020/06/01 00:00:00	1062				1530,48052						
2020/06/02 00:00:00	1986				1426,69032						
2020/06/03 00:00:00	1971				1712,75481						
2020/06/04 00:00:00	1873				1490,5792						
2020/06/05 00:00:00	1810				1435,47587						
2020/06/06 00:00:00	923				989,380078						
2020/06/07 00:00:00	780				864,237788						
2020/06/08 00:00:00	1755				1394,96429						
2020/06/09 00:00:00	1746				1698,2695						
2020/06/10 00:00:00	1832				1684,82804						
2020/06/11 00:00:00	1909				1563,66083						
2020/06/12 00:00:00	1884				1522,19391						
2020/06/13 00:00:00	1012				989,746169						
2020/06/14 00:00:00	820				862,146546						
2020/06/15 00:00:00	1964				1477,24538						
2020/06/16 00:00:00	1879				1751,87834						
2020/06/17 00:00:00	1808				1732,47542						
2020/06/18 00:00:00	1740				1620,84971						
2020/06/19 00:00:00	1748				1556,30072						
2020/06/20 00:00:00	1092				972,733902						
2020/06/21 00:00:00	944				875,661123						
2020/06/22 00:00:00	1871				1591,10131						
2020/06/23 00:00:00	1847				1751,22477						
2020/06/24 00:00:00	1916				1745,83756						
2020/06/25 00:00:00	2018				1668,87146						
2020/06/26 00:00:00	1942				1645,52131						
2020/06/27 00:00:00	1157				1023,93286						
2020/06/28 00:00:00	936				894,687933						
2020/06/29 00:00:00	1857				1638,83308						
2020/06/30 00:00:00	1855				1765,84742						
2020/07/01 00:00:00	1815				1777,80791						
2020/07/02 00:00:00	1819				1709,15007						

FIGURE 55 – Tableau predictive des appels par jours

Date	Value	prediction	lower	upper	fitted
2020/05/01 00:00:00	39414				39374,586
2020/06/01 00:00:00	47937				39414
2020/07/01 00:00:00	49028				47937
2020/08/01 00:00:00	45874				49028
2020/09/01 00:00:00	44549				45874
2020/10/01 00:00:00	44173				44549
2020/11/01 00:00:00	40041				44173
2020/12/01 00:00:00	42922				40041
2021/01/01 00:00:00	41175				42922
2021/02/01 00:00:00	38632				41175
2021/03/01 00:00:00	42191				38632
2021/04/01 00:00:00	38174				42191
2021/05/01 00:00:00	37408				38174
2021/06/01 00:00:00	21871				37408
2021/07/01 00:00:00		21871	11117,1554	32624,8446	21871
2021/08/01 00:00:00		21871	6662,76717	37079,2328	21871
2021/09/01 00:00:00		21871	3244,79483	40497,2052	21871
2021/10/01 00:00:00		21871	363,310866	43378,6891	21871
2021/11/01 00:00:00		21871	-2175,3275	45917,3275	21871
2021/12/01 00:00:00		21871	-4470,432	48212,432	21871
2022/01/01 00:00:00		21871	-6580,9984	50322,9984	21871
2022/02/01 00:00:00		21871	-8545,4657	52287,4657	21871
2022/03/01 00:00:00		21871	-10390,534	54132,5337	21871
2022/04/01 00:00:00		21871	-12135,642	55877,6424	21871
2022/05/01 00:00:00		21871	-13795,467	57537,4675	21871
2022/06/01 00:00:00		21871	-15381,41	59123,4103	21871
2022/07/01 00:00:00		21871	-16902,538	60644,538	21871
2022/08/01 00:00:00		21871	-18366,202	62108,202	21871
2022/09/01 00:00:00		21871	-19778,461	63520,4609	21871
2022/10/01 00:00:00		21871	-21144,378	64886,3783	21871
2022/11/01 00:00:00		21871	-22468,237	66210,237	21871
2022/12/01 00:00:00		21871	-23753,699	67495,6985	21871
2023/01/01 00:00:00		21871	-25003,922	68745,9217	21871
2023/02/01 00:00:00		21871	-26221,655	69963,6549	21871
2023/03/01 00:00:00		21871	-27409,307	71151,3067	21871
2023/04/01 00:00:00		21871	-28569,002	72311,002	21871
2023/05/01 00:00:00		21871	-29702,627	73444,6268	21871
2023/06/01 00:00:00		21871	-30811,864	74553,8639	21871
2023/07/01 00:00:00		21871	-31898,223	75640,2228	21871
2023/08/01 00:00:00		21871	-32963,063	76705,0633	21871
2023/09/01 00:00:00		21871	-34007,616	77749,6155	21871
2023/10/01 00:00:00		21871	-35032,997	78774,9967	21871

FIGURE 56 – Tableau predictive des sites critique